



Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Ingeniería Matemática y Computación

Sistema híbrido de detección de anomalías y Momentum Trading con algoritmos de clustering (K-Means/DBSCAN)

Trabajo fin de estudio presentado por:	Espejo Cuenca, Marcel Gómez Hernández, Raúl Martínez Díez, Diego
Tipo de trabajo:	Desarrollo Práctico
Director/a:	Martínez Cerdá, Juan Francisco
Fecha:	15/04/2026

Índice

1. Introducción	5
2. Contexto y estado del arte	7
2.1. El Momentum en los mercados financieros y el riesgo de anomalías	7
2.1.1. Fundamentación matemática del Momentum	7
2.1.2. Asimetría de riesgo y el concepto de estrategia basada en la persistencia de rendimientos (<i>momentum</i>) Crashes . . .	8
2.1.3. Ruido estructural, anomalías y la necesidad de filtrado topológico	10
2.2. Fundamentos de Machine Learning no supervisado	11
2.2.1. Algoritmo de Agrupamiento K-Means	11
2.2.2. Filtro de densidad topológica DBSCAN	13
2.3. Estado del arte y justificación de la arquitectura propuesta . . .	15
2.3.1. El problema del <i>Momentum</i> tradicional en entornos volátiles	16
2.3.2. El intento de solución mediante K-Means y sus limitaciones	16
2.3.3. Propuesta de Solución: Arquitectura Híbrida y Marco de Evaluación	16
3. Objetivos concretos y metodología de trabajo	17
3.1. Marco metodológico: CRISP-DM	18
3.2. Objetivo general	19

3.3.	Objetivos específicos	20
3.4.	Metodología del trabajo	20
3.4.1.	Obtención y comprensión de datos	20
3.4.2.	Preparación de datos	20
3.4.3.	Modelado	21
3.4.4.	Evaluación	21
3.5.	Organización del equipo de trabajo	21
3.6.	Planificación y coordinación	21
4.	Desarrollo específico de la contribución	22
4.1.	Selección de activos financieros y ETFs	23
4.2.	Construcción del conjunto de datos y análisis exploratorio de datos (EDA)	24
4.2.1.	Ventana temporal del análisis	25
4.2.2.	Descarga y construcción del conjunto de datos bruto	25
4.2.3.	Validación estructural y limpieza inicial	26
4.2.4.	Construcción y análisis de retornos financieros	27
4.2.5.	Distribución global de retornos y eventos extremos	27
4.2.6.	Análisis exploratorio avanzado	28
4.2.7.	Conclusiones del análisis exploratorio	32
4.3.	Transformación del Espacio de Características: estandarización dinámica mediante ventana móvil (<i>rolling Z-score</i>)	33
4.3.1.	Homogeneización mediante el Estadístico Z	33
4.3.2.	El problema del Sesgo de Información Futura	33
4.3.3.	Implementación del <i>rolling Z-score</i> dinámico	34
4.4.	Filtrado Topológico de Anomalías: DBSCAN	35
4.4.1.	Limitaciones del Análisis Longitudinal y Propuesta Cross- Sectional	35
4.4.2.	Calibración Dinámica de Hiperparámetros	36
4.5.	Resultados Empíricos del Filtrado de Anomalías	38
4.5.1.	Validación del modelo en entornos de alta volatilidad	39
4.6.	Segmentación de Regímenes de Mercado mediante K-Means	41
4.6.1.	Fundamentos del algoritmo K-Means	41
4.6.2.	Selección del espacio de características	42
4.6.3.	Selección del número óptimo de clusters	42
4.6.4.	Análisis comparativo de estructuras de <i>clustering</i>	44
4.6.5.	Perfil cuantitativo de los clusters	44
4.6.6.	Interpretación económica de los clusters	44
4.6.7.	Conclusiones del modelo K-Means	45

Índice de figuras

1.	Evolución de las caídas catastróficas en estrategias de <i>momentum</i> . Fuente: (Daniel & Moskowitz, 2016).	10
----	--	----

2.	Figura : Clasificación de activos en el espacio riesgo-rentabilidad mediante el algoritmo KMeans. Los puntos sólidos representan los centroides μ_i calculados según la Ecuación 2, mientras que las regiones sombreadas delimitan las fronteras de decisión de cada clúster. Fuente: Elaboración propia.	13
3.	Figura : Clasificación topológica en <i>Density-Based Spatial Clustering of Applications with Noise</i> (DBSCAN): Identificación de puntos núcleo, frontera y ruido en función del radio ϵ y MinPts. Fuente: Elaboración propia.	15
4.	Diagrama del proceso <i>Cross-Industry Standard Process for Data Mining</i> (CRISP-DM) adaptado al español. Fuente: elaboración propia a partir de (Jensen, 2012) bajo licencia CC BY-SA 3.0. . .	19
5.	Precios normalizados. Fuente: elaboración propia.	29
6.	Precios normalizados separando <i>Exchange Traded Fund</i> (fondo cotizado en bolsa) (ETF), activos de España y activos de EEUU. Fuente: elaboración propia.	30
7.	Histograma de distribución de retornos. Fuente: elaboración propia. .	31
8.	Matriz de correlación de retornos. Fuente: elaboración propia. . .	32
9.	Evolución de la volatilidad para el activo NVDA. Arriba: Serie nominal. Abajo: Serie tras la aplicación del Z-Score dinámico y convergencia hacia la media móvil ($\mu = 0$). El área sombreada denota el periodo de <i>warmup</i> (calentamiento). Fuente: Elaboración propia.	34
10.	Distribución de probabilidad empírica del estadístico Z para el activo NVDA. Fuente: Elaboración propia.	35
11.	Obtención de ϵ_t , aplicada a la sesión del 11 de marzo de 2020. El gráfico muestra el ordenamiento de las distancias al tercer vecino. El percentil 90 actúa como el umbral de densidad para la discriminación de ruido. Fuente: Elaboración propia.	37
12.	Evolución temporal del radio de vecindad adaptativo ϵ_t . La línea discontinua marca el límite inferior conservador. Fuente: Elaboración propia.	38
13.	Distribución temporal del filtrado de ruido. Fuente: Elaboración propia.	39
14.	Visualización topológica del colapso del 16 de marzo de 2020 mediante proyección <i>Principal Component Analysis</i> (análisis de componentes principales) (PCA). La cohesión del clúster principal refleja un movimiento generalizado del mercado ante un shock externo. Fuente: Elaboración propia.	40
15.	Método del codo para la selección del número óptimo de clusters. Fuente: elaboración propia.	43
16.	Evolución del Silhouette Score en función del número de clusters. Fuente: elaboración propia.	43

Índice de cuadros

1.	Rendimientos de las carteras superpuestas J/K de <i>momentum</i> . Fuente: (Jegadeesh & Titman, 1993).	8
2.	Universo de activos financieros utilizados en el sistema propuesto.	24
3.	Estadísticas del filtrado de ruido topológico generados por DBS- CAN.	38
4.	Comparativa de estructuras de técnica de agrupamiento no super- visado (<i>clustering</i>) para distintos valores de K.	44
5.	Perfil promedio de los clusters obtenidos para $K = 5$	44

Glosario de términos

<i>clustering</i>	técnica de agrupamiento no supervisado. 4, 6, 19, 21–23, 26, 31, 32, 41, 44
<i>drawdown</i>	caída máxima desde un máximo histórico. 9, 17
<i>machine learning</i>	aprendizaje automático. 6, 21
<i>momentum</i>	estrategia basada en la persistencia de rendimientos. 1, 3–10, 16, 19–22, 41, 45
<i>overfitting</i>	sobreajuste del modelo a los datos. 17
<i>rolling Z-score</i>	estandarización dinámica mediante ventana móvil. 2, 33–35, 41, 42, 44
<i>trading</i>	compraventa de activos financieros. 5, 6
ATR	<i>Average True Range</i> (rango verdadero medio). 45
CRISP-DM	<i>Cross-Industry Standard Process for Data Mining</i> . 3, 17–21
DBSCAN	<i>Density-Based Spatial Clustering of Applications with Noise</i> . 3, 4, 6, 7, 11, 13–15, 17, 19–22, 33, 35, 36, 38, 41, 45
EDA	<i>Exploratory Data Analysis</i> (análisis exploratorio de datos). 20, 22, 24
EMH	<i>Efficient Market Hypothesis</i> . 7
ETF	<i>Exchange Traded Fund</i> (fondo cotizado en bolsa). 3, 22–24, 27, 28, 30, 31
HME	Hipótesis del Mercado Eficiente. 7
IBEX 35	<i>índice bursátil español de referencia</i> . 23, 24

K-Means algoritmo de agrupamiento basado en centroides. 6, 7, 11, 13, 15–17, 19–22, 33, 41, 45

MACD *Moving Average Convergence Divergence*. 42, 45

PCA *Principal Component Analysis* (análisis de componentes principales). 3, 40

RSI *Relative Strength Index* (índice de fuerza relativa). 42, 45

S&P 500 índice bursátil Standard & Poor's 500. 17, 24

Sharpe ratio de Sharpe (rendimiento ajustado al riesgo). 8, 17

VIX *Volatility Index* (índice de volatilidad del mercado). 39

WCSS *Within-Cluster Sum of Squares*. 12

1. Introducción

En las últimas décadas, los mercados financieros han experimentado un crecimiento exponencial en la cantidad y complejidad de los datos disponibles, lo que ha impulsado el desarrollo de metodologías cuantitativas avanzadas para la toma de decisiones de inversión. En este contexto, la compraventa de activos compraventa de activos financieros (*trading*) se define como la actividad de comprar y vender instrumentos financieros —como acciones, bonos o derivados— con el objetivo de obtener beneficio económico. En su vertiente moderna, el *trading* se apoya cada vez más en modelos matemáticos y computacionales, dando lugar al denominado *trading* cuantitativo (López de Prado, 2018).

Dentro de este ámbito, una de las estrategias más relevantes es el impulso o inercia *momentum*, que puede definirse como la persistencia temporal en los rendimientos de los activos financieros. Este fenómeno implica que los activos que han tenido buen comportamiento en el pasado tienden a seguir mostrando rendimientos positivos en el corto plazo, mientras que los activos con mal rendimiento tienden a continuar su tendencia negativa. Esta anomalía fue documentada empíricamente por (Jegadeesh & Titman, 1993), y posteriormente reinterpretada desde una perspectiva de riesgo dinámico por (Daniel & Moskowitz, 2016), quienes destacan su relación con cambios en el estado del mercado y episodios de alta volatilidad.

No obstante, las estrategias de *momentum* presentan limitaciones importantes, especialmente en presencia de ruido estructural y valores atípicos (*outliers*). Como señala (López de Prado, 2018), los datos financieros están altamente contaminados por fenómenos que no reflejan la dinámica real del mercado, lo que dificulta la identificación de patrones fiables. En este contexto, el uso de

técnicas de aprendizaje automático aprendizaje automático (*machine learning*) se ha consolidado como una herramienta fundamental para el análisis de datos complejos.

En particular, el agrupamiento *clustering* es una técnica de aprendizaje no supervisado que consiste en organizar un conjunto de datos en grupos o clústeres, de forma que los elementos dentro de un mismo grupo sean más similares entre sí que con los de otros grupos. Este tipo de técnicas permite descubrir estructuras ocultas en los datos sin necesidad de información etiquetada previamente (Bishop, 2006).

Entre los algoritmos de agrupamiento *clustering* más utilizados destaca K-Medias algoritmo de agrupamiento basado en centroides (K-Means), un método que divide un conjunto de datos en un número predefinido de grupos, asignando cada observación al clúster cuyo centroide (media) es más cercano. El objetivo del algoritmo es minimizar la varianza interna de los clústeres, es decir, la distancia entre los puntos y su centroide. Este método fue formalizado por (MacQueen, 1967) y ha sido ampliamente utilizado en aplicaciones financieras, aunque presenta limitaciones importantes debido a su sensibilidad a valores atípicos.

Para abordar esta limitación, se emplean algoritmos más robustos como agrupamiento espacial basado en densidad con ruido (DBSCAN). Este algoritmo, propuesto por (Ester et al., 1996), define los clústeres como regiones de alta densidad de puntos separadas por regiones de baja densidad, permitiendo además identificar automáticamente observaciones anómalas (ruido). A diferencia de K-Means, DBSCAN no requiere especificar el número de clústeres y es capaz de detectar estructuras de forma arbitraria, lo que lo hace especialmente adecuado para datos financieros complejos.

En este contexto, el presente Trabajo Fin de Máster propone la integración de estas técnicas en una arquitectura híbrida orientada al análisis de mercados financieros. En particular, se plantea el uso de DBSCAN como mecanismo de filtrado de anomalías, seguido de la aplicación de K-Means para la identificación de patrones o regímenes de mercado. Esta aproximación permite mejorar la robustez de las estrategias de *momentum*, reduciendo el impacto del ruido y de los eventos extremos en la toma de decisiones.

El objetivo principal de este trabajo es, por tanto, diseñar, implementar y evaluar un sistema híbrido que combine estrategias de compra-venta de activos *trading* basadas en inercia *momentum* con algoritmos de agrupamiento *clustering*, con el fin de identificar patrones de comportamiento en activos financieros y mejorar la estabilidad de las estrategias de inversión en entornos de alta volatilidad. Este enfoque se sitúa en la intersección entre las finanzas cuantitativas y el aprendizaje automático, contribuyendo al desarrollo de metodologías más robustas y adaptativas en el análisis de mercados.

2. Contexto y estado del arte

El presente capítulo trata los fundamentos teóricos y matemáticos que sustentan la investigación, así como la revisión de la literatura contemporánea. En primer lugar, se analiza la naturaleza del *momentum* y su vulnerabilidad ante regímenes de alta volatilidad. Posteriormente, se muestran las herramientas de *Machine Learning* no supervisado propuestas (K-Means y DBSCAN), para finalizar con un análisis del estado del arte que justifica la arquitectura algorítmica híbrida de este trabajo.

2.1. El Momentum en los mercados financieros y el riesgo de anomalías

La persistencia de los rendimientos en los mercados de renta variable ha sido objeto de profundo debate en la literatura financiera. La Hipótesis del Mercado Eficiente (HME), o *Efficient Market Hypothesis* (EMH) establece que los precios reflejan instantáneamente toda la información disponible, imposibilitando la obtención sistemática de rendimientos anormales (Fama, 1970). Sin embargo, la evidencia empírica ha demostrado que los inversores tienden a reaccionar de forma ineficiente (por sobre-reacción o infra-reacción) ante la nueva información (Barberis et al., 1998; Hong & Stein, 1999), generando tendencias explotables matemáticamente. A la captura sistemática de estas tendencias se le conoce como inversión de *momentum*.

2.1.1. Fundamentación matemática del Momentum

El *momentum* se fundamenta en la premisa de que los activos que han obtenido un rendimiento superior en el pasado reciente continuarán haciéndolo en el futuro cercano, mientras que aquellos con un rendimiento deficiente seguirán una trayectoria bajista (Carhart, 1997; Jegadeesh & Titman, 1993). La formalización académica de esta estrategia fue establecida de forma pionera por (Jegadeesh & Titman, 1993), quienes demostraron que comprar acciones ganadoras y vender acciones perdedoras genera rendimientos anormales positivos y estadísticamente significativos.

La arquitectura matemática del modelo clásico de (Jegadeesh & Titman, 1993) se define mediante una estrategia de J meses de formación y K meses de mantenimiento (estrategia J/K). En el instante t , el universo de activos se clasifica en orden ascendente en función de sus rendimientos acumulados durante los pasados J meses. Basándose en este *ranking*, se forman diez carteras (deciles) equiponderadas. El decil superior se define como la cartera de "Ganadores" (*Winners*) y el decil inferior como la cartera de "Perdedores" (*Losers*).

La estrategia consiste en construir una cartera de inversión de coste cero (autofinanciada), tomando una posición larga en el decil de ganadores y una posición corta en el decil de perdedores, mantenida durante K periodos. Para maximizar el poder estadístico y evitar el sesgo de un único punto de entrada, se propone

el uso de carteras superpuestas (overlapping portfolios). En cualquier mes t , la estrategia mantiene una serie de carteras seleccionadas en el mes actual y en los $K - 1$ meses anteriores, rebalanceando mensualmente una fracción $1/K$ de los pesos del hiperespacio de activos.

		Panel A				Panel B					
J		$K =$	3	6	9	12	$K =$	3	6	9	12
3	Sell		0.0108 (2.16)	0.0091 (1.87)	0.0092 (1.92)	0.0087 (1.87)		0.0083 (1.67)	0.0079 (1.64)	0.0084 (1.77)	0.0083 (1.79)
3	Buy		0.0140 (3.57)	0.0149 (3.78)	0.0152 (3.83)	0.0156 (3.89)		0.0156 (3.95)	0.0158 (3.98)	0.0158 (3.96)	0.0160 (3.98)
3	Buy-sell		0.0032 (1.10)	0.0058 (2.29)	0.0061 (2.69)	0.0069 (3.53)		0.0073 (2.61)	0.0078 (3.16)	0.0074 (3.36)	0.0077 (4.00)
6	Sell		0.0087 (1.67)	0.0079 (1.56)	0.0072 (1.48)	0.0080 (1.66)		0.0066 (1.28)	0.0068 (1.35)	0.0067 (1.38)	0.0076 (1.58)
6	Buy		0.0171 (4.28)	0.0174 (4.33)	0.0174 (4.31)	0.0166 (4.13)		0.0179 (4.47)	0.0178 (4.41)	0.0175 (4.32)	0.0166 (4.13)
6	Buy-sell		0.0084 (2.44)	0.0095 (3.07)	0.0102 (3.76)	0.0086 (3.36)		0.0114 (3.37)	0.0110 (3.61)	0.0108 (4.01)	0.0090 (3.54)
9	Sell		0.0077 (1.47)	0.0065 (1.29)	0.0071 (1.43)	0.0082 (1.66)		0.0058 (1.13)	0.0058 (1.15)	0.0066 (1.34)	0.0078 (1.59)
9	Buy		0.0186 (4.56)	0.0186 (4.53)	0.0176 (4.30)	0.0164 (4.03)		0.0193 (4.72)	0.0188 (4.56)	0.0176 (4.30)	0.0164 (4.04)
9	Buy-sell		0.0109 (3.03)	0.0121 (3.78)	0.0105 (3.47)	0.0082 (2.89)		0.0135 (3.85)	0.0130 (4.09)	0.0109 (3.67)	0.0085 (3.04)
12	Sell		0.0060 (1.17)	0.0065 (1.29)	0.0075 (1.48)	0.0087 (1.74)		0.0048 (0.93)	0.0058 (1.15)	0.0070 (1.40)	0.0085 (1.71)
12	Buy		0.0192 (4.63)	0.0179 (4.36)	0.0168 (4.10)	0.0155 (3.81)		0.0196 (4.73)	0.0179 (4.36)	0.0167 (4.09)	0.0154 (3.79)
12	Buy-sell		0.0131 (3.74)	0.0114 (3.40)	0.0093 (2.95)	0.0068 (2.25)		0.0149 (4.28)	0.0121 (3.65)	0.0096 (3.09)	0.0069 (2.31)

Cuadro 1: Rendimientos de las carteras superpuestas J/K de *momentum*. Fuente: (Jegadeesh & Titman, 1993).

Esta formulación lineal clásica ha demostrado ser rentable, pero asume implícitamente una distribución estacionaria del riesgo, una suposición que resulta matemáticamente inestable en la práctica.

2.1.2. Asimetría de riesgo y el concepto de *momentum* Crashes

A pesar de sus altos rendimientos promedio y ratio de Sharpe (rendimiento ajustado al riesgo) (Sharpe) atractivos, la estrategia de *momentum* presenta un riesgo de cola. La distribución de sus rendimientos está fuertemente sesgada hacia la izquierda (Barroso & Santa-Clara, 2015), lo que significa que el modelo experimenta pérdidas infrecuentes pero devastadoras, conocidas en la literatura como colapsos de tendencia *Momentum Crashes* (Daniel & Moskowitz, 2016).

Daniel y Moskowitz demuestran que estos colapsos no son eventos aleatorios (saltos de Poisson), sino que son parcialmente predecibles al concentrarse en "estados de pánico" del mercado; es decir, tras caídas prolongadas (*bear markets*) combinadas con picos extremos de volatilidad esperada. La anatomía de una

caída (*crash*) tiene una forma contraintuitiva: el colapso de la estrategia no ocurre cuando el mercado sigue cayendo, sino exactamente cuando rebota de forma abrupta.

La justificación matemática radica en la variación dinámica de la beta (β) de las carteras extremas. Tras un declive severo, las acciones del decil de "Perdedores" han sufrido grandes caídas, quedando a menudo en situaciones de estrés financiero. En este punto, el capital de estas empresas actúa matemáticamente como una opción de compra (*call option*) fuera del dinero sobre los activos de la empresa. Mediante la introducción de variables indicadoras de mercado bajista (I_B) y alcista (I_U), en la literatura (Grundy & Martin, 2001) se demuestra que en estados de pánico, la cartera de perdedores presenta una asimetría extrema: su beta a la baja es moderada, pero su beta al alza se dispara ante cualquier rebote positivo.

Dado que el algoritmo de *momentum* obliga a mantener una posición corta sobre estos perdedores, la estrategia se encuentra efectivamente "corta en una opción de compra" sobre el índice del mercado. Cuando ocurre un rebote (ej. marzo-mayo de 2009), la cartera de perdedores sube destruyendo el margen de la posición corta, mientras que la cartera de ganadores apenas sube, generando un elevado declive caída máxima desde un máximo histórico (*drawdown*) en la estrategia.




Figura 1: Evolución de las caídas catastróficas en estrategias de *momentum*.
Fuente: (Daniel & Moskowitz, 2016).

2.1.3. Ruido estructural, anomalías y la necesidad de filtrado topológico

La evidencia de los *Momentum Crashes* y la inestabilidad de los modelos lineales subraya un desafío en la econometría financiera: la baja relación señal-ruido *signal-to-noise ratio* de las series temporales (Hasbrouck & Seppi, 2001; Roll & Ross, 1984). Como expone (López de Prado, 2018), los datos financieros están contaminados de forma continua por eventos de microestructura y anomalías

idiosincrásicas que no representan la dinámica real del mercado.

En este contexto, es crucial distinguir entre un cambio de régimen sistémico (donde la mayoría de los activos se desplazan conjuntamente, formando estructuras densas) y el ruido estructural o valores atípicos individuales (*outliers*). Los algoritmos de partición tradicionales, como K-Means, presentan una alta sensibilidad a estos últimos; la presencia de una sola acción con una rentabilidad extrema e injustificada puede desplazar significativamente los centroides, distorsionando la clasificación de todo el universo de activos.

Para solucionar esta limitación, la literatura técnica más reciente propone el uso de algoritmos basados en densidad. Específicamente, el algoritmo DBSCAN, Agrupamiento Espacial Basado en Densidad de Aplicaciones con Ruido, permite una aproximación topológica al filtrado de datos. A diferencia de los métodos de exclusión manuales o estáticos propuestos por autores como (Aslam, 2025), DBSCAN automatiza la identificación de anomalías basándose en la proximidad espacial de las observaciones (Shiraj et al., 2024). Aquellos activos que presenten movimientos de precio extremos, caídas repentinas *flash crashes* o patrones de volatilidad anómalos que no cuenten con una densidad mínima de “vecinos” con comportamiento similar, son etiquetados matemáticamente como ruido (*noise*).

Por consiguiente, se justifica la implementación de una arquitectura híbrida en este Trabajo. El uso de DBSCAN actúa como un paso de preprocesamiento para purgar las anomalías individuales y “cisnes negros” puntuales. Una vez eliminada esta contaminación estadística, el algoritmo K-Means puede clasificar los activos en regímenes de mercado robustos, garantizando que los centroides representen tendencias reales y no se vean afectados por el ruido estructural del mercado.

2.2. Fundamentos de Machine Learning no supervisado

Para abordar la naturaleza no lineal y ruidosa de los mercados financieros descrita en la sección anterior, esta investigación propone un sistema híbrido basado en dos de los algoritmos de aprendizaje no supervisado (*Unsupervised Learning*) más robustos: K-Means y DBSCAN (Bishop, 2006; Hastie et al., 2009). A diferencia del aprendizaje supervisado, estas técnicas no requieren datos etiquetados previamente, lo cual es idóneo para el descubrimiento de regímenes de mercado ocultos en series temporales multidimensionales. A continuación, se detallan sus fundamentos matemáticos.

2.2.1. Algoritmo de Agrupamiento K-Means

El algoritmo K-Means es un método iterativo que busca dividir un conjunto de n observaciones en un número predefinido de k clústeres disjuntos (Lloyd, 1982; MacQueen, 1967), de forma que cada observación pertenezca al clúster con el centroide (media) más cercano. Matemáticamente, dado un conjunto de vectores de características $X = \{x_1, x_2, \dots, x_n\}$ donde cada $x_i \in \mathbb{R}^d$ (siendo d el número de variables o indicadores financieros), el algoritmo tiene como objetivo minimizar la varianza intra-clúster. Esto se formula como la minimización de la

suma de los errores cuadráticos (*Within-Cluster Sum of Squares* (WCSS)) (Jain, 2010):

$$\arg \min_C \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

Ecuación . Minimización de la suma de los errores cuadráticos

$$\arg \min_C \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (1)$$

Donde $C = \{C_1, C_2, \dots, C_k\}$ representa el conjunto de clústeres y μ_i es el centroide del clúster C_i , calculado como la media aritmética de los puntos asignados a dicho clúster:

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$$

Ecuación . Media aritmética de los puntos del clúster

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x \quad (2)$$

El proceso de optimización utiliza comúnmente la distancia euclídea como métrica de similitud en el hiperespacio d -dimensional:

$$d(x, y) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2} \quad (3)$$




Figura 2: Figura : Clasificación de activos en el espacio riesgo-rentabilidad mediante el algoritmo KMeans. Los puntos sólidos representan los centroides μ_i calculados según la Ecuación 2, mientras que las regiones sombreadas delimitan las fronteras de decisión de cada clúster. Fuente: Elaboración propia.

A pesar de su eficiencia computacional $\mathcal{O}(nki)$, el algoritmo clásico presenta dos limitaciones críticas en finanzas: asume que los clústeres tienen forma esférica (convergencia isométrica) y, al carecer de un concepto de densidad, se ve forzado a asignar todos los puntos a un clúster. Como indica la Ecuación 2, un valor atípico extremo alterará el sumatorio, desplazando el centroide μ_i y sesgando la identificación del régimen de mercado.

2.2.2. Filtro de densidad topológica DBSCAN

Para mitigar la fragilidad del K-Means ante valores extremos, se implementa el algoritmo DBSCAN, Agrupamiento Espacial Basado en Densidad de Aplicaciones con Ruido (*Density-Based Spatial Clustering of Applications with Noise*) propuesto por (Ester et al., 1996). A diferencia de los métodos de partición, DBSCAN define los clústeres como regiones continuas de alta densidad de puntos separadas por regiones de baja densidad, permitiendo además la detección

automática de valores atípicos *outliers* (Schubert, 2017).

La topología de DBSCAN se rige fundamentalmente por dos hiperparámetros espaciales:

- ϵ (*Epsilon*): El radio máximo de vecindad alrededor de un punto.
- *MinPts*: El número mínimo de puntos requeridos dentro de la vecindad ϵ para considerar que existe una región densa.

Para cualquier punto p , su ϵ - vecindad se define matemáticamente como el subconjunto de puntos q en la base de datos D cuya distancia a p es menor o igual a ϵ :

$$N_\epsilon(p) = \{q \in D \mid \text{dist}(p, q) \leq \epsilon\} \quad (4)$$

En base a esta vecindad, el algoritmo clasifica todas las observaciones del hiperespacio en tres categorías topológicas distintas:

1. Puntos Núcleo (*Core Points*): Un punto p es un núcleo si $|N_\epsilon(p)| \geq \text{MinPts}$. Estos puntos conforman el interior (esqueleto) de un régimen de mercado.
2. Puntos Frontera (*Border Points*): Un punto q es frontera si $|N_\epsilon(q)| < \text{MinPts}$, pero pertenece a la ϵ - vecindad de un punto núcleo.
3. Ruido (*Noise / Outliers*): Cualquier punto o que no es ni núcleo ni frontera. Matemáticamente, son puntos aislados que no alcanzan la densidad crítica.




Figura 3: Figura : Clasificación topológica en DBSCAN: Identificación de puntos núcleo, frontera y ruido en función del radio ϵ y MinPts. Fuente: Elaboración propia.

En el marco de esta investigación, el objetivo primario de DBSCAN no es la clasificación final de los regímenes, sino la capacidad para detectar los puntos clasificados como "Ruido". Al asignar matemáticamente la etiqueta -1 a las anomalías idiosincrásicas (como el *Flash Crash* previamente ilustrado), el algoritmo permite purgar el hiperespacio de características antes de someterlo a la minimización de la varianza del K-Means.

2.3. Estado del arte y justificación de la arquitectura propuesta

La aplicación de técnicas de *Machine Learning* no supervisado en la optimización de carteras ha experimentado un crecimiento exponencial (Gu et al., 2020; López de Prado, 2018). Sin embargo, la comunidad científica aún debate cómo gestionar la disrupción que generan las anomalías del mercado sobre los algoritmos clásicos. A continuación, se articula el estado de la cuestión siguiendo la evolución desde el problema tradicional hasta la propuesta arquitectónica de esta investigación.

2.3.1. El problema del *Momentum* tradicional en entornos volátiles

La selección de activos para conformar carteras de *momentum* ha incrementado su complejidad metodológica. Según advierte (Aslam, 2025), esta toma de decisiones representa en la actualidad un desafío mayúsculo debido a la alta volatilidad inherente a los mercados. El autor sugiere que el *momentum* transversal estándar es a menudo insuficiente en estos entornos de estrés, lo que justifica de manera imperativa la aplicación de algoritmos de Aprendizaje Automático *Machine Learning* para el desarrollo de una "estrategia de *momentum* gestionada por riesgo".

En paralelo, (Shiraj et al., 2024) exponen en su análisis que los mercados financieros están expuestos de forma recurrente a movimientos extremos de precios repentinos. Estos eventos anómalos o *crashes*, si no son detectados y aislados a tiempo, actúan como un factor de contaminación estadística capaz de invalidar por completo los modelos predictivos y de clasificación subyacentes.

2.3.2. El intento de solución mediante K-Means y sus limitaciones

Como respuesta a esta necesidad de adaptación dinámica, la literatura reciente ha explorado modelos de agrupamiento basados en partición. (Aslam, 2025) propone la utilización del algoritmo K-Means para clasificar el universo de activos basándose en características multidimensionales de riesgo y retorno. Su enfoque permite la identificación algorítmica de clústeres compuestos por las denominadas "acciones optimistas", superando los resultados de los deciles tradicionales.

Adicionalmente, otros trabajos contemporáneos como el de (Luan & Hamp, 2025) evidencian la necesidad de automatizar la clasificación de regímenes en series temporales multidimensionales, proponiendo variantes avanzadas del K-Means (como el *Sliced Wasserstein K-Means*) para tratar de lidiar con la complejidad de las distribuciones financieras.

No obstante, esta línea de solución presenta una limitación técnica crítica advertida por (Nyffeler & Weibel, 2024): el algoritmo K-Means tradicional posee una sensibilidad matemática inherente a los valores atípicos (*outliers*). Dado que minimiza la suma de los errores cuadráticos global, la presencia de anomalías genera una severa inestabilidad en la asignación de los clústeres y una distorsión artificial en la ubicación de los centroides. Esta vulnerabilidad es ejemplificada de manera concluyente por (Bin, 2020), quien documenta cómo la caída extrema de una sola empresa (Apache Corp, -70 %) es capaz de desplazar los centroides y comprometer el rendimiento de toda una cartera K-Means.

2.3.3. Propuesta de Solución: Arquitectura Híbrida y Marco de Evaluación

La revisión del estado del arte evidencia una brecha: los algoritmos particionales (K-Means) agrupan eficientemente el riesgo, pero son incapaces de discrimi-

nar eventos irracionales, mientras que los algoritmos de densidad (DBSCAN) identifican las anomalías, pero no segmentan el mercado direccionalmente.

Para resolver esta problemática, el presente Trabajo propone una solución híbrida. Integrando las advertencias de (Shiraj et al., 2024) y la necesidad de gestión de riesgo de (Aslam, 2025), se establece una arquitectura secuencial: el algoritmo DBSCAN actuará como preprocesador para detectar y aislar matemáticamente las anomalías, protegiendo así al modelo. Posteriormente, K-Means clasificará el espacio de datos ya purgado, asegurando que los centroides representen los verdaderos regímenes de "acciones optimistas" sin la distorsión del ruido estructural.

Para validar de forma empírica la superioridad de esta arquitectura y mitigar el riesgo de sobreajuste del modelo a los datos (*overfitting*) advertido por (López de Prado, 2018), los hiperparámetros se optimizarán en una ventana de entrenamiento (*in-sample*) y se evaluarán en un periodo cronológico estrictamente posterior (*out-of-sample*). La investigación contrastará tres escenarios de inversión:

1. Benchmark (Referencia): Rentabilidad pasiva del índice índice bursátil Standard & Poor's 500 (S&P 500) (Comprar y mantener).
2. Modelo Base: Estrategia algorítmica utilizando K-Means aislado.
3. Modelo Híbrido (Propuesta): Implementación secuencial de DBSCAN seguido de K-Means.

La robustez de los modelos se medirá a través de métricas institucionales clave: el Sharpe y el *Maximum drawdown* (riesgo de caída máxima). El objetivo final de la experimentación será demostrar matemáticamente que el filtrado previo de anomalías reduce de forma efectiva las pérdidas de la cartera durante los escenarios de estrés del mercado.

3. Objetivos concretos y metodología de trabajo

En este capítulo se definen los objetivos del trabajo y la metodología seguida para su desarrollo. Este apartado actúa como nexo entre el estudio del contexto y estado del arte presentado anteriormente y la implementación práctica de la propuesta planteada.

El trabajo se enmarca en el ámbito del análisis de datos financieros mediante técnicas de *Machine Learning*, con el objetivo de desarrollar y evaluar una arquitectura algorítmica híbrida capaz de identificar patrones de comportamiento en activos financieros y reducir el impacto de anomalías en entornos de alta volatilidad.

3.1. Marco metodológico: CRISP-DM

La metodología adoptada en este trabajo se basa en el estándar CRISP-DM, traducido como *Proceso Estándar Intersectorial para Minería de Datos*. Este marco fue desarrollado por un consorcio de empresas tecnológicas europeas, entre ellas *SPSS*, *Daimler-Benz* y *NCR*, como respuesta a la necesidad de estandarizar los procesos de proyectos de *minería de datos* en distintos dominios industriales (Chapman, 2000).

CRISP-DM se ha consolidado como una de las metodologías más utilizadas en proyectos de ciencia de datos debido a su carácter iterativo, flexible y centrado en el problema de negocio (Wirth & Hipp, 2000). Su estructura permite adaptar el ciclo de vida del proyecto a entornos complejos como los mercados financieros, caracterizados por ruido, no estacionariedad e incertidumbre.

El modelo CRISP-DM se compone de seis fases: (1) comprensión del negocio, (2) comprensión de los datos, (3) preparación de los datos, (4) modelado, (5) evaluación y (6) despliegue.

En este trabajo, estas fases se utilizan como marco de referencia para estructurar el desarrollo del sistema propuesto, adaptándolas al contexto del análisis de datos financieros.

En la Figura 4 se presenta una representación del ciclo CRISP-DM, el cual sirve como guía metodológica en el desarrollo del presente trabajo.




Figura 4: Diagrama del proceso CRISP-DM adaptado al español. Fuente: elaboración propia a partir de (Jensen, 2012) bajo licencia CC BY-SA 3.0.

3.2. Objetivo general

El objetivo general de este trabajo es diseñar, implementar y evaluar una arquitectura híbrida basada en técnicas de *clustering* (DBSCAN y K-Means) que permita identificar patrones de comportamiento en activos financieros y mejorar la robustez de las estrategias de *momentum* mediante el filtrado previo de anomalías.

Para ello, se desarrollará un sistema capaz de agrupar activos con dinámicas similares tras un proceso de depuración del ruido estructural, generando señales indicativas de posibles oportunidades de inversión o eventos atípicos.

El sistema propuesto será evaluado con el fin de analizar su utilidad en la interpretación del comportamiento del mercado y en la toma de decisiones basada en datos.

3.3. Objetivos específicos

Los objetivos específicos del trabajo se derivan del planteamiento general y se encuentran alineados de forma indirecta con las fases del modelo CRISP-DM, que se utiliza como marco metodológico de referencia:

1. **Recopilar** datos históricos de precios de activos financieros.
2. **Analizar** la estructura de los datos y realizar análisis exploratorio.
3. **Preprocesar y limpiar** el conjunto de datos.
4. **Transformar** series temporales en variables relevantes.
5. **Implementar** una arquitectura secuencial basada en DBSCAN y K-Means.
6. **Aplicar** DBSCAN para detección de anomalías.
7. **Aplicar** K-Means sobre datos depurados.
8. **Analizar** e interpretar los clústeres obtenidos.
9. **Integrar** una estrategia de *momentum* como marco de evaluación.
10. **Comparar** el modelo híbrido frente a un modelo base.
11. **Evaluar** el rendimiento con datos no vistos.
12. **Validar** la utilidad del modelo en entorno experimental.

3.4. Metodología del trabajo

La metodología del presente trabajo se basa en la aplicación práctica del marco CRISP-DM al desarrollo del sistema propuesto, estructurando el proceso en fases iterativas que permiten la retroalimentación continua entre obtención de datos, modelado y evaluación.

El proceso global se organiza en cuatro bloques principales: obtención y comprensión de datos, preparación de datos, modelado y evaluación.

3.4.1. Obtención y comprensión de datos

Se recopilan series temporales de activos financieros (precios de apertura, cierre, máximos, mínimos y volumen) a partir de fuentes públicas. Posteriormente, se realiza un *Exploratory Data Analysis* (análisis exploratorio de datos) (EDA) para identificar patrones, distribuciones y posibles anomalías.

3.4.2. Preparación de datos

Se realiza la limpieza del conjunto de datos mediante la eliminación de valores nulos, normalización de variables y transformación de precios en retornos y medidas de volatilidad.

3.4.3. Modelado

Se implementa una arquitectura híbrida en dos etapas: DBSCAN como filtro de anomalías y K-Means como algoritmo de segmentación de regímenes de mercado.

3.4.4. Evaluación

Se evalúa el sistema mediante comparación con un modelo base y una estrategia tradicional de *momentum*, utilizando métricas financieras como rentabilidad y estabilidad.

3.5. Organización del equipo de trabajo

El desarrollo del proyecto se ha realizado de forma colaborativa entre los tres integrantes del equipo, estableciendo una distribución de responsabilidades orientada a facilitar la coordinación, aunque con participación transversal en todas las fases del proyecto.

- **Espejo Cuenca, Marcel:** diseño e implementación de la arquitectura de *machine learning*, incluyendo los algoritmos de *clustering* (DBSCAN y K-Means) y la construcción del sistema híbrido.
- **Gómez Hernández, Raúl:** obtención, limpieza y transformación de los datos financieros, así como el diseño del pipeline de preprocesamiento.
- **Martínez Díez, Diego:** análisis exploratorio de datos, revisión bibliográfica, apoyo en la interpretación de resultados y redacción de la memoria.

A pesar de esta distribución inicial, el trabajo ha sido completamente colaborativo, participando los tres integrantes en el diseño, validación y toma de decisiones técnicas del proyecto.

3.6. Planificación y coordinación

El equipo mantiene un sistema de reuniones periódicas:

- Reuniones semanales de seguimiento del estado del proyecto.
- Reuniones adicionales en fases críticas (preprocesamiento, modelado y evaluación).

Estas reuniones permiten revisar avances, resolver problemas técnicos y alinear decisiones metodológicas bajo el marco de CRISP-DM.

Para la coordinación del desarrollo del proyecto se ha utilizado *Git*, un sistema de control de versiones que permite registrar y gestionar los cambios realizados sobre el código a lo largo del tiempo. Como repositorio central se ha empleado *GitHub*, una plataforma en línea que facilita el trabajo colaborativo, el almacenamiento del código y la sincronización entre los distintos miembros del equipo.

Estas herramientas han permitido gestionar el desarrollo de forma estructurada, mantener un historial de cambios y facilitar la integración de las distintas partes del sistema implementado.

4. Desarrollo específico de la contribución

En este capítulo se describe el desarrollo completo de la contribución propuesta en el presente Trabajo de Fin de Máster, orientada al análisis no supervisado de activos financieros mediante técnicas de aprendizaje automático y análisis cuantitativo.

El objetivo principal del sistema desarrollado consiste en identificar estructuras de comportamiento dentro de los mercados financieros y detectar observaciones anómalas a partir de información histórica de precios y variables derivadas. Para ello, se propone un enfoque híbrido basado en técnicas de *clustering* y detección de anomalías aplicadas sobre series temporales financieras.

En primer lugar, se presenta el proceso de selección del universo de activos financieros y ETF utilizados en el estudio, justificando la inclusión de distintos mercados, sectores económicos y factores de riesgo. Posteriormente, se detalla la construcción del conjunto de datos y el proceso de EDA, incluyendo las fases de descarga, validación, limpieza y caracterización estadística inicial de las series financieras.

A continuación, se abordará la construcción de variables e indicadores financieros derivados, orientados a representar propiedades relevantes del mercado como rentabilidad, volatilidad, *momentum* o comportamiento relativo entre activos. Estas variables servirán como entrada para las etapas posteriores de modelado.

Sobre este conjunto de características financieras se aplicará un enfoque híbrido compuesto por dos técnicas principales de aprendizaje no supervisado:

- En primer lugar, se empleará el algoritmo DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) con el objetivo de detectar y filtrar observaciones anómalas o regiones de baja densidad dentro del espacio de datos.
- Posteriormente, sobre el conjunto de observaciones filtradas, se aplicará el algoritmo K-Means para identificar agrupaciones de activos con comportamientos financieros similares.

La combinación de ambas técnicas permite construir un sistema más robusto frente a ruido y eventos extremos, algo especialmente relevante en entornos financieros reales caracterizados por alta volatilidad, distribuciones no gaussianas y presencia frecuente de anomalías de mercado.

Finalmente, se presentarán los resultados obtenidos, analizando tanto la calidad de los clusters generados como la capacidad del sistema para identificar patrones relevantes y comportamientos atípicos dentro del universo financiero analizado.

4.1. Selección de activos financieros y ETFs

Para el desarrollo del sistema propuesto, se ha definido un conjunto diversificado de activos financieros compuesto por acciones individuales y ETF, con el objetivo de capturar distintos regímenes de mercado y estructuras sectoriales.

En concreto, se han seleccionado:

- Acciones del mercado español (*índice bursátil español de referencia* (IBEX 35)), representativas de distintos sectores.
- Acciones del mercado estadounidense, caracterizadas por alta liquidez y relevancia global.
- ETF sectoriales y de mercado, que permiten capturar dinámicas agregadas y factores sistemáticos.

La inclusión de activos de distintos mercados y sectores responde al principio de diversificación en carteras financieras, ampliamente establecido en la literatura desde la teoría moderna de carteras (Markowitz, 1952), y posteriormente desarrollado en el contexto de construcción de carteras eficientes (Elton & Gruber, 1997). Esta diversidad permite capturar comportamientos heterogéneos y reducir sesgos asociados a un único mercado.

Asimismo, la combinación de mercados internacionales se justifica por la existencia de dinámicas diferenciadas entre regiones geográficas, especialmente entre mercados desarrollados, tal y como se ha documentado en estudios sobre integración financiera internacional (Bekaert & Harvey, 1995).

Por otro lado, el uso de ETF permite representar de forma eficiente factores de mercado y sectores económicos completos, actuando como aproximaciones agregadas del comportamiento del mercado y reduciendo el impacto del ruido idiosincrático de activos individuales (Madhavan, 2012).

Además, la inclusión de activos pertenecientes a distintos sectores económicos se fundamenta en la evidencia de que los retornos presentan estructuras diferenciadas en función del sector, lo que resulta relevante en tareas de segmentación y *clustering* financiero (Fama & French, 1997).

Finalmente, la selección de activos líquidos y ampliamente negociados responde a la necesidad de garantizar la calidad de los datos y evitar distorsiones asociadas a problemas de iliquidez, tal y como se ha señalado en la literatura sobre microestructura de mercados (Amihud, 2002).

En la Tabla 2 se presenta el universo de activos financieros utilizado en el desarrollo del sistema propuesto, incluyendo acciones de los mercados español y estadounidense, así como distintos ETF representativos de sectores, índices y factores de riesgo.

Ticker	Activo	Categoría
Mercado España (IBEX 35)		
SAN.MC	Banco Santander	Acción
FER.MC	Ferrovial	Acción
ACS.MC	ACS	Acción
ITX.MC	Inditex	Acción
REP.MC	Repsol	Acción
AMS.MC	Amadeus IT Group	Acción
Mercado Estados Unidos		
AAPL	Apple Inc.	Acción
MSFT	Microsoft	Acción
NVDA	NVIDIA	Acción
JPM	JPMorgan Chase	Acción
BLK	BlackRock	Acción
TSLA	Tesla	Acción
DPZ	Domino's Pizza	Acción
CAT	Caterpillar	Acción
XOM	Exxon Mobil	Acción
ETF		
XLK	Technology Select Sector ETF	ETF Sectorial
SMH	Semiconductor ETF	ETF Sectorial
XLV	Health Care ETF	ETF Sectorial
XLI	Industrial ETF	ETF Sectorial
XLY	Consumer Discretionary ETF	ETF Sectorial
XLP	Consumer Staples ETF	ETF Sectorial
GLD	SPDR Gold Trust	ETF Materias Primas
SPY	S&P 500 ETF	ETF Índice
QQQ	Nasdaq-100 ETF	ETF Índice
EWP	Spain ETF	ETF País
MTUM	Momentum Factor ETF	ETF Factorial
XLE	Energy ETF	ETF Sectorial
XLF	Financials ETF	ETF Sectorial
TLT	Treasury Bonds ETF	ETF Renta Fija
XLU	Utilities ETF	ETF Sectorial

Cuadro 2: Universo de activos financieros utilizados en el sistema propuesto.

4.2. Construcción del conjunto de datos y análisis exploratorio de datos (EDA)

Una vez definido el universo de activos financieros utilizado en el estudio, se procedió a la construcción y análisis inicial del conjunto de datos financiero.

Como paso previo al modelado, se realizó un proceso de EDA (Tukey, 1977),

conocido en español como análisis exploratorio de datos. El EDA constituye una etapa fundamental dentro de cualquier flujo de trabajo de ciencia de datos y análisis cuantitativo, ya que permite comprender la estructura del conjunto de datos, detectar posibles problemas de calidad, identificar patrones relevantes y validar que la información disponible es adecuada para las técnicas estadísticas y de aprendizaje automático que se aplicarán posteriormente.

En el contexto financiero, esta fase resulta especialmente importante debido a que las series temporales de mercado suelen presentar características complejas, como volatilidad heterogénea, correlaciones dinámicas, valores extremos y comportamientos no gaussianos.

4.2.1. Ventana temporal del análisis

El periodo temporal seleccionado para el estudio abarca desde enero de 2017 hasta mayo de 2026. La elección de esta ventana temporal responde a la necesidad de incorporar distintos regímenes de mercado y ciclos económicos completos, incluyendo tanto fases expansivas como periodos de elevada incertidumbre financiera.

En particular, este horizonte temporal permite incluir eventos sistémicos relevantes como:

- La crisis financiera derivada de la pandemia COVID-19.
- El periodo inflacionario posterior a 2021.
- Distintas fases de recuperación y desaceleración de mercado.

Además, disponer de un histórico amplio resulta especialmente útil para el cálculo posterior de métricas financieras basadas en ventanas temporales, tales como volatilidades móviles, indicadores técnicos o medidas de correlación.

4.2.2. Descarga y construcción del conjunto de datos bruto

Los datos financieros fueron descargados mediante la librería `yfinance`, que proporciona acceso programático a información histórica de mercado obtenida desde Yahoo Finance (Aroussi, 2025; Yahoo Finance, 2026).

Para cada activo financiero se descargaron las siguientes variables diarias:

- Precio de cierre ajustado (`Precio_Adj`).
- Precio máximo diario (`High`).
- Precio mínimo diario (`Low`).
- Volumen negociado (`Volumen`).

Inicialmente, la información fue obtenida en formato matricial, donde cada columna representaba un activo financiero y cada fila correspondía a una fecha concreta. Posteriormente, las distintas variables fueron unificadas en un único

DataFrame en formato panel o *long format*, estructura ampliamente utilizada en análisis financiero multivariante.

En el conjunto de datos final, cada fila representa un activo financiero en una fecha específica, quedando definida mediante las siguientes variables:

- **Fecha:** Fecha de cotización.
- **Ticker:** Identificador bursátil del activo.
- **Precio_Adj:** Precio de cierre ajustado.
- **High:** Precio máximo diario.
- **Low:** Precio mínimo diario.
- **Volumen:** Volumen de negociación diario.

Esta estructura facilita posteriormente la aplicación de transformaciones por activo, cálculos temporales y técnicas de *clustering* sobre observaciones multivariantes.

4.2.3. Validación estructural y limpieza inicial

Una vez construido el conjunto de datos bruto, se realizó una validación estructural inicial con el objetivo de comprobar la calidad y consistencia de los datos descargados.

Durante esta fase se analizaron aspectos como:

- la presencia de valores nulos,
- el rango temporal disponible para cada activo,
- la consistencia de los tipos de datos,
- y la correcta alineación temporal entre series financieras.

El análisis reveló la existencia de valores faltantes principalmente concentrados al inicio de algunas series temporales. Este comportamiento es habitual en bases de datos financieras y puede deberse a diferencias en las fechas de cotización, festivos bursátiles o limitaciones históricas del proveedor de datos.

Tras esta inspección inicial, se aplicó un proceso básico de limpieza consistente en:

- Eliminación de observaciones con información crítica faltante.
- Reorganización cronológica de las series.
- Validación de la cobertura mínima de cada activo.

Como resultado, se obtuvo un conjunto de datos homogéneo y estructuralmente consistente para su posterior análisis cuantitativo.

4.2.4. Construcción y análisis de retornos financieros

A partir de los precios ajustados se calcularon los retornos diarios de cada activo financiero. En finanzas, el retorno representa la variación porcentual del precio entre dos instantes consecutivos y constituye una de las variables fundamentales para medir rentabilidad y riesgo.

El uso de retornos, en lugar de precios absolutos, permite comparar activos con escalas de precio completamente diferentes. Por ejemplo, acciones tecnológicas con precios elevados pueden analizarse conjuntamente con ETF o activos de menor valor nominal sin introducir sesgos derivados de la escala.

Posteriormente, se realizó un análisis estadístico descriptivo de los retornos, estudiando métricas como:

- Media.
- Desviación estándar.
- Asimetría (*skewness*).
- Curtosis (*kurtosis*).

La desviación estándar se utilizó como medida de volatilidad, entendida como el grado de variabilidad de los retornos de un activo. Los resultados mostraron diferencias significativas entre activos financieros.

En particular, activos tecnológicos como NVIDIA o Tesla presentaron niveles de volatilidad considerablemente superiores al resto del universo analizado. Asimismo, estos activos mostraron distribuciones más asimétricas y con curtosis elevada.

La curtosis mide el peso de las colas de una distribución estadística. Valores elevados de curtosis indican una mayor frecuencia de eventos extremos respecto a lo esperado bajo una distribución normal, fenómeno característico de los mercados financieros reales y ampliamente documentado en la literatura financiera (Cont, 2001).

4.2.5. Distribución global de retornos y eventos extremos

Además del análisis individual por activo, se estudió la distribución agregada de retornos del conjunto completo del mercado analizado.

Los resultados mostraron una distribución aproximadamente centrada en cero, aunque con presencia clara de colas pesadas (*fat tails*), indicando una frecuencia de movimientos extremos superior a la esperada bajo hipótesis gaussianas.

En términos financieros, este comportamiento implica que eventos de mercado muy intensos —caídas o subidas bruscas— ocurren con mayor frecuencia de lo que asumirían modelos estadísticos basados en distribuciones normales.

Con el objetivo de estudiar estos episodios, se identificaron observaciones extremas definidas como retornos absolutos superiores al 10 %.

El análisis permitió detectar múltiples eventos asociados a periodos de elevada volatilidad, especialmente durante marzo de 2020, coincidiendo con el impacto global de la pandemia COVID-19 sobre los mercados financieros. Asimismo, se observaron movimientos extremos en activos tecnológicos y sectores especialmente sensibles a shocks macroeconómicos.

La existencia de estos eventos extremos refuerza la necesidad de emplear modelos robustos capaces de capturar dinámicas no lineales y comportamientos anómalos dentro del mercado.

4.2.6. Análisis exploratorio avanzado

Finalmente, se desarrolló una fase de análisis exploratorio avanzado mediante visualizaciones y métricas multivariantes orientadas a comprender la dinámica conjunta de los activos financieros.

En primer lugar, se analizaron series temporales normalizadas de precios. La normalización permite representar todos los activos sobre una escala comparable, facilitando el análisis visual de su evolución relativa independientemente de su precio nominal.

Los resultados mostraron una fuerte concentración del crecimiento en el sector tecnológico, destacando especialmente NVIDIA, Tesla y el ETF de semiconductores (SMH) como los activos con mayor revalorización acumulada durante el periodo estudiado.

Al segmentar el análisis por regiones geográficas, se observó que:

- en el mercado español destacaron ACS y Ferrovial,
- mientras que en el mercado estadounidense sobresalieron NVIDIA y Tesla.

También se identificó visualmente el impacto sistémico de la crisis del COVID-19, reflejado en caídas sincronizadas entre la mayoría de activos financieros Figura 5 y Figura 6.




Figura 5: Precios normalizados. Fuente: elaboración propia.




Figura 6: Precios normalizados separando ETF, activos de españa y activos de EEUU. Fuente: elaboración propia.

Posteriormente, se analizó la distribución visual de retornos mediante histogramas Figura 7. Aunque la distribución presentaba una forma aproximadamente simétrica alrededor de cero, el análisis estadístico realizado anteriormente confirmó que los retornos financieros no siguen una distribución normal estricta debido a la presencia de colas pesadas y eventos extremos.




Figura 7: Histograma de distribución de retornos. Fuente: elaboración propia.

Finalmente, se construyó una matriz de correlación entre activos financieros Figura 8. La correlación mide el grado de relación lineal entre dos variables y constituye una herramienta fundamental para comprender estructuras de dependencia dentro de los mercados (Markowitz, 1952).

El análisis mostró que:

- Los activos tecnológicos presentaban correlaciones elevadas entre sí.
- Los ETF de renta fija como TLT mostraban baja correlación respecto al resto del mercado.
- Activos refugio como GLD mantenían un comportamiento relativamente independiente.

Estas estructuras de dependencia resultan especialmente relevantes para las fases posteriores de *clustering* y detección de anomalías, ya que permiten identificar grupos de activos con dinámicas similares y posibles comportamientos atípicos dentro del sistema financiero analizado.




Figura 8: Matriz de correlación de retornos. Fuente: elaboración propia.

4.2.7. Conclusiones del análisis exploratorio

El análisis exploratorio realizado permitió validar la calidad y consistencia del conjunto de datos, además de identificar múltiples propiedades relevantes del mercado financiero analizado.

Entre las principales conclusiones obtenidas destacan:

- La elevada heterogeneidad entre activos financieros.
- La existencia de volatilidad extrema y eventos no gaussianos.
- La presencia de estructuras de correlación claramente diferenciadas.
- La fuerte concentración del crecimiento en determinados sectores tecnológicos.

Estas observaciones justifican la posterior construcción de variables financieras avanzadas y la aplicación de técnicas de *clustering* y detección de anomalías sobre el conjunto de datos.

4.3. Transformación del Espacio de Características: *rolling Z-score*

Tal y como se ha evidenciado en las conclusiones del análisis exploratorio, las características extraídas de los activos presentan escalas y unidades de medida heterogéneas. En la estructura de datos tipo panel que se maneja, conviven variables de distinta naturaleza: desde el volumen de negociación cuantificado en millones de unidades hasta los retornos logarítmicos situados en órdenes de magnitud de milésimas.

En el aprendizaje no supervisado, tanto los algoritmos basados en densidad (DBSCAN) como los basados en partición de centroides (K-Means) fundamentan su capacidad de clasificación en métricas de distancia geométrica, generalmente la distancia Euclídea. Introducir los datos brutos en este tipo de modelos generaría un sesgo estructural severo: aquellas variables con mayor escala nominal dominarían por completo el cálculo de las distancias, invalidando la contribución informativa de los indicadores financieros con rangos menores.

4.3.1. Homogeneización mediante el Estadístico Z

Para garantizar una base de datos equitativa donde cada variable contribuya proporcionalmente a la topología del modelo, es necesario realizar una normalización. Se ha optado por implementar la estandarización Z-Score, la cual transforma cada variable para que posea una media (μ) igual a cero y una desviación estándar (σ) unitaria.

Matemáticamente, la transformación clásica para una observación x se define en la Ecuación 5:

$$Z = \frac{x - \mu}{\sigma} \quad (5)$$

Esta transformación constituye un requisito fundamental en finanzas cuantitativas, especialmente en metodologías basadas en distancias. Al aplicar la estandarización Z-Score, se eliminan los efectos derivados de las distintas escalas y magnitudes originales de las variables, permitiendo que la distancia euclídea entre vectores capture diferencias relativas de comportamiento y no magnitudes absolutas.

4.3.2. El problema del Sesgo de Información Futura

A pesar de su utilidad, la normalización tradicional aplicada directamente sobre series temporales introduce un problema metodológico crítico conocido como sesgo de información futura.

Si se calculase la media y la varianza utilizando toda la serie histórica para normalizar un dato del pasado, el modelo estaría incorporando implícitamente información de eventos posteriores (como la crisis del COVID). Esto introduce

una fuga de información que invalidaría el análisis, ya que el sistema estaría utilizando datos que no eran conocidos por el mercado en el instante t .

4.3.3. Implementación del *rolling Z-score* dinámico

Para evitar este problema y respetar la estructura temporal de los datos, se ha desarrollado una función de estandarización dinámica denominada `estandarizar_zscore_rolling`. Dado que los mercados financieros son no estacionarios, se utiliza una ventana móvil de $w = 252$ sesiones, equivalente a un año bursátil.

El valor de la característica i en el instante t se normaliza exclusivamente con su histórico previo disponible, según la Ecuación 6:

$$Z_{i,t} = \frac{x_{i,t} - \mu_{i,[t-w,t-1]}}{\sigma_{i,[t-w,t-1]}} \quad (6)$$

Esto garantiza la estricta causalidad temporal del sistema. El impacto longitudinal de esta transformación se ilustra en la Figura 9, donde se observa la estabilización de la serie y el intervalo de seguridad inicial (área sombreada) correspondiente al periodo de *warmup* (calentamiento).




Figura 9: Evolución de la volatilidad para el activo NVDA. Arriba: Serie nominal. Abajo: Serie tras la aplicación del Z-Score dinámico y convergencia hacia la media móvil ($\mu = 0$). El área sombreada denota el periodo de *warmup* (calentamiento). Fuente: Elaboración propia.

Finalmente, la Figura 10 confirma que la variable transformada presenta propiedades distribucionales adecuadas para el aprendizaje no supervisado, concentrando la mayor densidad de observaciones en torno al origen y facilitando la separación topológica de observaciones extremas.

En este caso, el estadístico representado corresponde específicamente al Z-Score dinámico de la volatilidad a 21 días (*Volatilidad_21d_Z*) del activo NVDA, tal y como se define en la Figura 9.




Figura 10: Distribución de probabilidad empírica del estadístico Z para el activo NVDA. Fuente: Elaboración propia.

4.4. Filtrado Topológico de Anomalías: DBSCAN

Una vez estandarizadas las variables mediante el estadístico *rolling Z-score* (Sección 4.3), se tiene una matriz de datos estacionaria donde las distancias Euclídeas entre vectores de activos que son directamente comparables al encontrarse las variables expresadas en una escala homogénea. El siguiente paso en la arquitectura del sistema consiste en la identificación y filtrado del ruido mediante el algoritmo de agrupamiento basado en densidad, DBSCAN.

4.4.1. Limitaciones del Análisis Longitudinal y Propuesta Cross-Sectional

En la literatura convencional de *Machine Learning*, el filtrado de valores atípicos suele ejecutarse de forma longitudinal, alimentando al algoritmo con la matriz que contiene la serie temporal completa. Sin embargo, en el mundo de las finanzas, este enfoque contiene un defecto a destacar: la incapacidad de distinguir entre una anomalía local y un cambio de régimen de mercado.

Si el algoritmo DBSCAN procesara de manera conjunta la década completa de datos financieros, detectaría los periodos de pánico extremo (como el colapso

de los mercados en marzo de 2020 a raíz del COVID) como una disonancia global. En consecuencia, el algoritmo eliminaría años enteros de observaciones, introduciendo un grave sesgo de supervivencia en los datos.

Para evitar esta limitación y mantener la información que corresponde a las colas pesadas de la distribución, el presente estudio propone un algoritmo (*Cross-Sectional*) que se implementa mediante un bucle secuencial (`for fecha in sorted(fechas)`), de forma que los datos se analizan día a día de manera independiente.

Matemáticamente, para cada instante de cotización t , se define una matriz de características $X_t \in \mathbb{R}^{N_t \times d}$, donde N_t representa el número de activos disponibles en esa sesión y d es el número de variables consideradas. En este esquema, el cálculo de distancias se realiza únicamente entre activos dentro del mismo día, por lo que el modelo analiza cómo se comporta cada activo en relación con el resto en esa misma sesión. Esto permite identificar aquellos activos que se alejan del comportamiento general del mercado en un día concreto.

En el caso de un evento de mercado extremo, como una caída generalizada, todos los activos tienden a moverse de forma similar entre sí, por lo que sus relaciones relativas se mantienen estables. De este modo, el sistema no interpreta estas situaciones como ruido, sino como un comportamiento válido del mercado bajo ese contexto.

4.4.2. Calibración Dinámica de Hiperparámetros

El rendimiento del algoritmo DBSCAN depende de forma crítica de la elección de sus hiperparámetros, en particular el radio de vecindad (ϵ) y el número mínimo de puntos por grupo (*min_samples*), también conocido como umbral mínimo de densidad. En el contexto de mercados financieros, donde la variabilidad entre activos cambia de una sesión a otra, el uso de parámetros fijos no resulta adecuado, ya que puede provocar tanto una eliminación excesiva de observaciones en periodos de alta volatilidad como una baja capacidad de detección en fases de mercado más estables.

Para resolver este problema, se ha diseñado una estrategia de calibración dinámica basada en los propios datos del sistema, de forma que los hiperparámetros se ajustan automáticamente en cada instante t :

- **Imposición de cuórum topológico (*min_samples*):** Para evitar que pequeños clústeres marginales o errores puntuales en los precios sean interpretados como estructuras válidas, se exige un tamaño mínimo de grupo. Este umbral se fija de forma proporcional al universo de activos disponible en cada sesión, utilizando el 10 % del total, con un límite inferior que garantiza que siempre sea posible formar al menos un grupo significativo:

$$\text{min_samples}_t = \max(3, \lceil 0,10 \times N_t \rceil) \quad (7)$$

- **Cálculo adaptativo del radio de vecindad (ϵ_t):** En lugar de fijar un hiperparámetro de distancia fijo, el modelo ajusta este parámetro en función de la distribución diaria de distancias entre activos. Se calcula la distancia euclidiana de cada activo $i \in X_t$ a su k -ésimo vecino más cercano, fijando $k = 3$. Sea $D_{i,3}$ dicha distancia, el hiperparámetro ϵ_t se calibra dinámicamente sobre el **percentil 90** de esta distribución de distancias, lo que permite adaptar el radio a las condiciones de dispersión del mercado en cada sesión.

Adicionalmente, para prevenir que el algoritmo se vuelva hiper-restrictivo en espacios de menor dimensionalidad, se ha introducido un límite inferior (*suelo adaptativo*) proporcional a la raíz cuadrada de la dimensión del espacio de características:

$$\epsilon_t = \max \left(0,2 \cdot \sqrt{d}, P_{90} \left(\{D_{i,3}\}_{i=1}^{N_t} \right) \right) \quad (8)$$




Figura 11: Obtención de ϵ_t , aplicada a la sesión del 11 de marzo de 2020. El gráfico muestra el ordenamiento de las distancias al tercer vecino. El percentil 90 actúa como el umbral de densidad para la discriminación de ruido. Fuente: Elaboración propia.

Esta formulación permite que el radio de análisis se adapte al estado del mercado en cada sesión. En periodos de alta volatilidad, el umbral de distancia se amplía, lo que evita que movimientos generalizados del mercado sean interpretados como anomalías. En cambio, en fases más estables, el criterio se vuelve más restrictivo, pudiendo activar el límite inferior de seguridad cuando la dispersión es excesivamente baja, como se ilustra en la Figura 12. Como resultado, el sistema no trata los cambios globales del mercado como ruido, sino que se centra en identificar únicamente aquellos activos que se separan de forma significativa del comportamiento general en cada sesión.




Figura 12: Evolución temporal del radio de vecindad adaptativo ϵ_t . La línea discontinua marca el límite inferior conservador. Fuente: Elaboración propia.

4.5. Resultados Empíricos del Filtrado de Anomalías

La implementación del modelo topológico descrito en la sección anterior se ha ejecutado sobre el conjunto de variables previamente estandarizado. El procedimiento recorre el dataset de forma secuencial, analizando cada fecha de manera independiente. Para cada instante t , el algoritmo asigna a cada activo una etiqueta en función de su comportamiento relativo dentro de esa sesión. Aquellos activos que no cumplen simultáneamente el tamaño mínimo de grupo definido en la Ecuación 7 ni el criterio de proximidad establecido por el radio adaptativo de la Ecuación 8 son clasificados automáticamente como ruido, recibiendo la etiqueta -1 .

En la Tabla 3 se exponen las métricas globales resultantes de la ejecución del proceso de filtrado.

Métricas (DBSCAN Cross-Sectional)	Valor
Total de sesiones procesadas (T)	2.415
Volumen total de observaciones evaluadas ($N \times T$)	70.758
Anomalías identificadas y purgadas (Etiqueta -1)	2.365
Porcentaje de observaciones eliminadas	3,34 %

Cuadro 3: Estadísticas del filtrado de ruido topológico generados por DBSCAN.




Figura 13: Distribución temporal del filtrado de ruido. Fuente: Elaboración propia.

La proporción de datos eliminados se mantiene en niveles moderados a lo largo de todo el periodo analizado. Este resultado es coherente con el comportamiento esperado del sistema y respalda la adaptabilidad del parámetro ϵ_t . El objetivo del modelo no es reducir de forma agresiva el conjunto de datos, sino eliminar únicamente observaciones extremas que corresponden a ruido idiosincrático, preservando la estructura general del mercado representada por la mayoría de los activos.

4.5.1. Validación del modelo en entornos de alta volatilidad

La validez de un modelo de *Machine Learning* aplicado a finanzas no se demuestra únicamente mediante propiedades matemáticas, sino también comprobando que sus resultados sean coherentes con situaciones reales observadas en el mercado. Un caso especialmente relevante para evaluar la robustez del sistema es el colapso financiero de marzo de 2020.

Durante la sesión del 16 de marzo de 2020, el índice *Volatility Index* (índice de volatilidad del mercado) (VIX) alcanzó niveles históricamente elevados y los principales índices bursátiles registraron caídas superiores al 11 %. Un enfoque tradicional basado en el análisis longitudinal podría haber interpretado este episodio como una anomalía estructural del conjunto de datos. Sin embargo, el enfoque *Cross-Sectional* analiza cada sesión de forma independiente, identificando que la caída generalizada responde a un comportamiento conjunto del mercado (*riesgo sistémico*) y no a errores aislados en los datos.




Figura 14: Visualización topológica del colapso del 16 de marzo de 2020 mediante proyección PCA. La cohesión del clúster principal refleja un movimiento generalizado del mercado ante un shock externo. Fuente: Elaboración propia.

Como puede observarse en la Figura 14, el algoritmo no eliminó ningún activo durante esa sesión. A pesar de las fuertes caídas registradas, los valores mantuvieron un comportamiento relativamente homogéneo entre sí dentro del espacio de características. No obstante, conviene realizar dos precisiones técnicas sobre esta representación:

- Efecto de la reducción de dimensionalidad: Aunque en la proyección bidimensional obtenida mediante PCA algunos activos puedan aparecer en posiciones periféricas, esto responde en muchos casos a una limitación propia de la representación visual. Al reducir un espacio multidimensional a dos componentes principales, parte de la información se pierde. Sin embargo, en el espacio original, dichos activos continúan situándose dentro de las distancias permitidas por el radio ϵ_t calculado por el modelo.
- Adaptabilidad del radio de vecindad: En días de volatilidad elevada, la dispersión natural entre observaciones aumenta. Gracias al cálculo dinámico del percentil 90 de distancias, el umbral ϵ_t se amplía automáticamente, permitiendo que el clúster principal incorpore el movimiento conjunto del mercado sin clasificar erróneamente activos válidos como ruido.

En definitiva, este sistema de filtrado actúa como una herramienta de depuración inteligente. Permite eliminar ruido sin perder la información relevante asociada

a los grandes movimientos del mercado, garantizando que la matriz resultante ($\tilde{X}$) conserve una estructura limpia. Este paso facilita posteriormente que el algoritmo K-Means converja de forma más estable y pueda identificar los distintos regímenes de mercado en las fases posteriores del estudio.

4.6. Segmentación de Regímenes de Mercado mediante K-Means

Una vez depurado el conjunto de datos mediante el filtrado topológico basado en DBSCAN, el siguiente paso del sistema consiste en identificar estructuras internas dentro del mercado utilizando técnicas de aprendizaje no supervisado basadas en partición.

Con este objetivo, se ha aplicado el algoritmo K-Means sobre el conjunto de observaciones previamente filtrado. La finalidad de esta etapa no es predecir directamente precios futuros, sino identificar regímenes de comportamiento financiero homogéneos dentro del espacio de características construido en las fases anteriores.

El algoritmo K-Means se aplica sobre un espacio previamente estandarizado mediante *rolling Z-score* y depurado de ruido mediante DBSCAN, lo que garantiza la comparabilidad geométrica entre observaciones y la validez del uso de distancias euclídeas.

4.6.1. Fundamentos del algoritmo K-Means

K-Means es un algoritmo de *clustering* no supervisado que particiona un conjunto de observaciones en K grupos minimizando la distancia intra-cluster (MacQueen, 1967). Formalmente, el objetivo del algoritmo es minimizar la función:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 \quad (9)$$

donde μ_k representa el centroide del cluster C_k .

En el contexto financiero, esta partición permite agrupar observaciones con perfiles similares de *momentum*, volatilidad e indicadores técnicos.

4.6.1.1. Inicialización mediante K-Means++ Para mejorar la estabilidad del algoritmo y evitar soluciones subóptimas asociadas a inicializaciones aleatorias, se utiliza la variante K-Means++. Este método selecciona los centroides iniciales de forma probabilística, favoreciendo puntos alejados entre sí.

Este enfoque mejora la convergencia del algoritmo, reduce la varianza entre ejecuciones y resulta especialmente relevante en espacios financieros de alta dimensionalidad, donde la sensibilidad a la inicialización puede afectar significativamente a la solución final.

4.6.2. Selección del espacio de características

El modelo se construye sobre un conjunto de variables financieras derivadas, obtenidas a partir de transformaciones sobre precios, retornos e indicadores técnicos, con el objetivo de capturar distintas dimensiones del comportamiento del mercado.

Estas variables no se utilizan en su forma original, sino que han sido previamente transformadas mediante el estadístico *rolling Z-score* (Sección 4.3), lo que garantiza su comparabilidad temporal y transversal entre activos.

De forma conceptual, el espacio de características puede agruparse en cuatro bloques principales:

- **Momentum multiescala:** captura la dinámica direccional del precio en distintos horizontes temporales (largo, medio y corto plazo).
- **Indicadores técnicos:** variables derivadas de análisis técnico clásico como *Relative Strength Index* (índice de fuerza relativa) (RSI) y *Moving Average Convergence Divergence* (MACD), utilizadas para medir sobrecompra, sobreventa y cambios de tendencia.
- **Volatilidad:** medidas de dispersión del precio que reflejan el nivel de incertidumbre del mercado.
- **Actividad relativa:** variables relacionadas con el volumen negociado y su comportamiento respecto a su distribución histórica.

En este contexto, el conjunto final de variables utilizado en el modelo se define como:

- ALR12M_SKIP_Z (momentum largo plazo)
- ALR6M_SKIP_Z (momentum medio plazo)
- ALR1M_SKIP_Z (momentum corto plazo)
- MACD_Hist_Z (oscilador de tendencia)
- RSI_14_Z (fuerza relativa del precio)
- Volatilidad_252d_Z (volatilidad anualizada)
- ATR_14_Z (rango verdadero medio)
- Vol_Relativo_Z (actividad de mercado relativa)

4.6.3. Selección del número óptimo de clusters

La elección del número de clusters K se ha abordado mediante dos metodologías complementarias:

- Método del codo (Elbow Method).
- Coeficiente de silueta (Silhouette Score).




Figura 15: Método del codo para la selección del número óptimo de clusters.
Fuente: elaboración propia.

El método del codo muestra una disminución progresiva de la inercia, observándose una desaceleración del beneficio marginal a partir de valores intermedios de K .




Figura 16: Evolución del Silhouette Score en función del número de clusters.
Fuente: elaboración propia.

El coeficiente de silueta presenta una estabilización a partir de $K = 5$, lo que sugiere que incrementos adicionales en la complejidad del modelo no aportan

mejoras significativas en la separación de clusters.

Aunque valores inferiores de K presentan métricas ligeramente superiores, estos generan una segmentación excesivamente agregada desde el punto de vista financiero, reduciendo la interpretabilidad económica del sistema.

En consecuencia, se selecciona $K = 5$ como compromiso entre estabilidad estadística e interpretabilidad económica.

4.6.4. Análisis comparativo de estructuras de *clustering*

Se analiza la evolución de la estructura de clusters para distintos valores de K con el objetivo de evaluar la estabilidad de las particiones.

K	Distribución	Interpretación
3	Muy agregada	Baja granularidad, pérdida de detalle
4	Intermedia	Mejora interpretativa
5	Óptima	Equilibrio entre detalle y estabilidad
6	Sobreespecificación	Fragmentación de regímenes

Cuadro 4: Comparativa de estructuras de *clustering* para distintos valores de K .

4.6.5. Perfil cuantitativo de los clusters

A continuación se presenta el perfil promedio de los clusters obtenidos para $K = 5$, que constituye la configuración final del modelo.

Cabe destacar que todas las variables utilizadas en el *clustering* corresponden a transformaciones estandarizadas mediante *rolling Z-score*, por lo que los valores reflejan desviaciones respecto a su media histórica y no niveles absolutos de los indicadores.

Cluster	Momentum L/P	Momentum C/P	RSI	MACD	Volatilidad	ATR	Vol Relativo
0	-0.92	-0.84	-0.65	-0.22	0.66	0.35	-0.08
1	-1.48	-1.32	0.75	0.95	1.18	0.35	-0.27
2	0.56	0.42	0.96	0.56	-0.82	-0.23	0.01
3	1.09	0.88	-0.51	-0.54	-0.77	0.16	-0.18
4	0.34	0.42	-1.65	-2.00	0.69	2.57	0.92

Cuadro 5: Perfil promedio de los clusters obtenidos para $K = 5$.

4.6.6. Interpretación económica de los clusters

A partir de los centroides obtenidos, se procede a la interpretación económica de cada cluster en términos de régimen de mercado.

4.6.6.1. Cluster 0 — Régimen bajista moderado Este cluster se caracteriza por valores negativos en *momentum* de largo y medio plazo, junto con niveles bajos de indicadores técnicos como RSI y MACD. La volatilidad se sitúa en niveles moderados.

Representa fases de mercado bajista sostenido sin episodios extremos de pánico o capitulación.

4.6.6.2. Cluster 1 — Rebote en mercado bajista Se observa un patrón mixto, con *momentum* negativo en horizontes largos, pero recuperación en el corto plazo reflejada en MACD y RSI positivos. La volatilidad es elevada.

Este cluster corresponde a rebotes técnicos dentro de tendencias bajistas más amplias.

4.6.6.3. Cluster 2 — Régimen alcista estable Presenta *momentum* positivo en todos los horizontes, acompañado de indicadores técnicos favorables y baja volatilidad.

Representa un entorno de mercado alcista estable y continuo.

4.6.6.4. Cluster 3 — Pullback en tendencia alcista Se observa fortaleza en el largo plazo, pero debilidad en el corto plazo. Esto sugiere correcciones temporales dentro de tendencias alcistas consolidadas.

La volatilidad se mantiene contenida, lo que refuerza la interpretación de consolidación.

4.6.6.5. Cluster 4 — Régimen de estrés o capitulación Este cluster presenta caídas extremas en *momentum* de corto plazo, valores muy negativos en MACD y RSI, y niveles elevados de volatilidad y *Average True Range* (rango verdadero medio) (ATR).

Representa episodios de estrés extremo de mercado o movimientos de capitulación.

4.6.7. Conclusiones del modelo K-Means

Los resultados muestran que el algoritmo K-Means permite transformar el espacio continuo de variables financieras en una representación discreta de regímenes de mercado interpretables.

La arquitectura final del sistema combina dos etapas complementarias:

- DBSCAN, encargado de la eliminación de ruido y observaciones anómalas.
- K-Means++, encargado de la estructuración del espacio en regímenes de mercado.

La configuración $K = 5$ se selecciona como solución final por proporcionar un equilibrio adecuado entre interpretabilidad económica y estabilidad estadística.

Referencias

- Amihud, Y. (2002). Illiquidity and stock returns: cross-section and time-series effects. *Journal of financial markets*, 5(1), 31-56.
- Aroussi, R. (2025). *yfinance: Yahoo! Finance market data downloader* [Accedido: 2026-05-09]. <https://github.com/ranaroussi/yfinance>
- Aslam, B. (2025). Identifying optimistic stocks with K-means clustering algorithm. *International Review of Economics & Finance*, 104579.
- Barberis, N., Shleifer, A., & Vishny, R. (1998). A Model of Investor Sentiment. *Journal of Financial Economics*, 49, 307-343.
- Barroso, P., & Santa-Clara, P. (2015). Momentum has its moments. *Journal of Financial Economics*, 116(1), 111-120. <https://doi.org/https://doi.org/10.1016/j.jfineco.2014.11.010>
- Bekaert, G., & Harvey, C. R. (1995). Time-Varying World Market Integration. *The Journal of Finance*, 50(2), 403-444. <https://doi.org/https://doi.org/10.1111/j.1540-6261.1995.tb04790.x>
- Bin, S. (2020). K-means stock clustering analysis based on historical price movements and financial ratios.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Carhart, M. M. (1997). On Persistence in Mutual Fund Performance. *The Journal of Finance*, 52(1), 57-82. <https://doi.org/https://doi.org/10.1111/j.1540-6261.1997.tb03808.x>
- Chapman, P. (2000). CRISP-DM 1.0: Step-by-step data mining guide. <https://api.semanticscholar.org/CorpusID:59777418>
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223-236.
- Daniel, K., & Moskowitz, T. J. (2016). Momentum Crashes. *Journal of Financial Economics*, 122(2), 221-247.
- Elton, E. J., & Gruber, M. J. (1997). Modern portfolio theory, 1950 to date. *Journal of Banking & Finance*, 21(11), 1743-1759. [https://doi.org/http://doi.org/10.1016/S0378-4266\(97\)00048-4](https://doi.org/http://doi.org/10.1016/S0378-4266(97)00048-4)
- Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, 226-231.
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383-417. Consultado el 13 de mayo de 2026, desde <http://www.jstor.org/stable/2325486>
- Fama, E. F., & French, K. R. (1997). Industry costs of equity. *Journal of financial economics*, 43(2), 153-193.

- Grundy, B. D., & Martin, J. S. M. (2001). Understanding the Nature of the Risks and the Source of the Rewards to Momentum Investing. *The Review of Financial Studies*, 14(1), 29-78. <https://doi.org/10.1093/rfs/14.1.29>
- Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33, 2223-2273.
- Hasbrouck, J., & Seppi, D. J. (2001). Common factors in prices, order flows, and liquidity. *Journal of Financial Economics*, 59(3), 383-411. [https://doi.org/10.1016/S0304-405X\(00\)00091-X](https://doi.org/10.1016/S0304-405X(00)00091-X)
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Hong, H., & Stein, J. (1999). A Unified Theory of Underreaction, Momentum Trading, and Overreaction. *The Journal of Finance*, 54, 2143-2184.
- Jain, A. K. (2010). Data Clustering: 50 Years Beyond K-Means. *Pattern Recognition Letters*, 31, 651-666.
- Jegadeesh, N., & Titman, S. (1993). Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. *The Journal of Finance*, 48(1), 65-91.
- Jensen, K. (2012). CRISP-DM Process Diagram [Licencia CC BY-SA 3.0, consultado el 2026-05-01]. https://commons.wikimedia.org/wiki/File:CRISP-DM_Process_Diagram.png
- Lloyd, S. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129-137. <https://doi.org/10.1109/TIT.1982.1056489>
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- Luan, Q., & Hamp, J. (2025). Automated regime classification in multidimensional time series data using sliced Wasserstein k-means clustering. *Data Science in Finance and Economics*, 5(3), 387-418.
- MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281-297.
- Madhavan, A. (2012). Exchange-traded funds, market structure, and the flash crash. *Financial Analysts Journal*, 68(4), 20-35.
- Markowitz, H. (1952). Modern portfolio theory. *Journal of Finance*, 7(11), 77-91.
- Nyffeler, L. R., & Weibel, M. (2024). *Classification of S&P 500 Stocks into Value and Growth: A Practical Application of K-Means Clustering and Mahalanobis Distance* (inf. téc.). ZHAW Zürcher Hochschule für Angewandte Wissenschaften.
- Roll, R., & Ross, S. A. (1984). The Arbitrage Pricing Theory Approach to Strategic Portfolio Planning. *Financial Analysts Journal*, 40(3), 14-26. <https://doi.org/10.2469/faj.v40.n3.14>
- Schubert, E. e. a. (2017). DBSCAN Revisited. *ACM Transactions on Database Systems*.
- Shiraj, M. M. B., Rahman, M. M., Al-Imran, M., Liza, M. Z. A., Murshed, M. M., & Akhter, N. (2024). Anomaly detection in financial time series data via mapper algorithm and DBSCAN clustering. *World Journal of Advanced Engineering Technology and Sciences*, 13(1), 70-84.

- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining, 1*, 29-39.
- Yahoo Finance. (2026). Yahoo Finance [Accedido: 2026-05-09]. <https://finance.yahoo.com/>