



Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Ingeniería Matemática y Computación

Sistema híbrido de detección de anomalías y Momentum Trading con algoritmos de clustering (K-Means/DBSCAN)

Trabajo fin de estudio presentado por:	Espejo Cuenca, Marcel Gómez Hernández, Raúl Martínez Díez, Diego
Tipo de trabajo:	Desarrollo Práctico
Director/a:	Martínez Cerdá, Juan Francisco
Fecha:	15/04/2026

Índice

1. Introducción	3
2. Contexto y estado del arte	4
2.1. El Momentum en los mercados financieros y el riesgo de anomalías	4
2.1.1. Fundamentación matemática del Momentum	5
2.1.2. Asimetría de riesgo y el concepto de <i>Momentum</i> Crashes .	6
2.1.3. Ruido estructural, anomalías y la necesidad de filtrado topológico	8
2.2. Fundamentos de Machine Learning no supervisado	9
2.2.1. Algoritmo de Agrupamiento K-Means	9
2.2.2. Filtro de densidad topológica DBSCAN	11
2.3. Estado del arte y justificación de la arquitectura propuesta . . .	13
2.3.1. El problema del <i>Momentum</i> tradicional en entornos volátiles	14
2.3.2. El intento de solución mediante K-Means y sus limitaciones	14
2.3.3. Propuesta de Solución: Arquitectura Híbrida y Marco de Evaluación	14
3. Objetivos concretos y metodología de trabajo	15
3.1. Marco metodológico: CRISP-DM	15
3.2. Objetivo general	17
3.3. Objetivos específicos	18

3.4. Metodología del trabajo	18
3.4.1. Obtención y comprensión de datos	18
3.4.2. Preparación de datos	18
3.4.3. Modelado	19
3.4.4. Evaluación	19
3.5. Organización del equipo de trabajo	19
3.6. Planificación y coordinación	19
4. Desarrollo específico de la contribución	20
4.1. Selección de activos financieros y ETFs	20
5. Referencias bibliográficas	22

Índice de figuras

1. Evolución de las caídas catastróficas en estrategias de momentum. Fuente: Daniel y Moskowitz (2016).	8
2. Figura : Clasificación de activos en el espacio riesgo-rentabilidad mediante el algoritmo KMeans. Los puntos sólidos representan los centroides μ_i calculados según la Ecuación 2, mientras que las regiones sombreadas delimitan las fronteras de decisión de cada clúster. Fuente: Elaboración propia.	11
3. Figura : Clasificación topológica en DBSCAN: Identificación de puntos núcleo, frontera y ruido en función del radio ϵ y MinPts. Fuente: Elaboración propia.	13
4. Diagrama del proceso CRISP-DM adaptado al español. Fuente: elaboración propia a partir de (Jensen, 2012) bajo licencia CC BY-SA 3.0.	17

Índice de cuadros

1. Rendimientos de las carteras superpuestas J/K de momentum. Fuente: Jegadeesh y Titman (1993).	6
2. Universo de activos financieros utilizados en el sistema propuesto.	21

Índice de ecuaciones

Ecuación 1. Minimización de la suma de los errores cuadráticos	12
Ecuación 2. Media aritmética de los puntos del clúster	12
Ecuación 3. Distancia euclídea	13
Ecuación 4. Vecindad	14

1. Introducción

En las últimas décadas, los mercados financieros han experimentado un crecimiento exponencial en la cantidad y complejidad de los datos disponibles, lo que ha impulsado el desarrollo de metodologías cuantitativas avanzadas para la toma de decisiones de inversión. En este contexto, la compraventa de activos (*trading*) se define como la actividad de comprar y vender instrumentos financieros —como acciones, bonos o derivados— con el objetivo de obtener beneficio económico. En su vertiente moderna, el *trading* se apoya cada vez más en modelos matemáticos y computacionales, dando lugar al denominado *trading* cuantitativo (López de Prado, 2018).

Dentro de este ámbito, una de las estrategias más relevantes es el impulso o inercia (*momentum*), que puede definirse como la persistencia temporal en los rendimientos de los activos financieros. Este fenómeno implica que los activos que han tenido buen comportamiento en el pasado tienden a seguir mostrando rendimientos positivos en el corto plazo, mientras que los activos con mal rendimiento tienden a continuar su tendencia negativa. Esta anomalía fue documentada empíricamente por Narendra Jegadeesh y Sheridan Titman (1993), y posteriormente reinterpretada desde una perspectiva de riesgo dinámico por Kent Daniel y Tobias Moskowitz (2016), quienes destacan su relación con cambios en el estado del mercado y episodios de alta volatilidad.

No obstante, las estrategias de *momentum* presentan limitaciones importantes, especialmente en presencia de ruido estructural y valores atípicos (*outliers*). Como señala Marcos López de Prado (2018), los datos financieros están altamente contaminados por fenómenos que no reflejan la dinámica real del mercado, lo que dificulta la identificación de patrones fiables. En este contexto, el uso de técnicas de aprendizaje automático (*machine learning*) se ha consolidado como una herramienta fundamental para el análisis de datos complejos.

En particular, el agrupamiento (*clustering*) es una técnica de aprendizaje no supervisado que consiste en organizar un conjunto de datos en grupos o clústeres, de forma que los elementos dentro de un mismo grupo sean más similares entre sí que con los de otros grupos. Este tipo de técnicas permite descubrir estructuras ocultas en los datos sin necesidad de información etiquetada previamente (Bishop, 2006).

Entre los algoritmos de agrupamiento (*clustering*) más utilizados destaca K-Medias (*K-Means*), un método que divide un conjunto de datos en un número predefinido de grupos, asignando cada observación al clúster cuyo centroide (media) es más cercano. El objetivo del algoritmo es minimizar la varianza interna de los clústeres, es decir, la distancia entre los puntos y su centroide. Este método fue formalizado por MacQueen (1967) y ha sido ampliamente utilizado en aplicaciones financieras, aunque presenta limitaciones importantes debido a su sensibilidad a valores atípicos.

Para abordar esta limitación, se emplean algoritmos más robustos como agrupa-

miento espacial basado en densidad con ruido *DBSCAN* (*Density-Based Spatial Clustering of Applications with Noise*). Este algoritmo, propuesto por Ester (1996), define los clústeres como regiones de alta densidad de puntos separadas por regiones de baja densidad, permitiendo además identificar automáticamente observaciones anómalas (ruido). A diferencia de *K-Means*, *DBSCAN* no requiere especificar el número de clústeres y es capaz de detectar estructuras de forma arbitraria, lo que lo hace especialmente adecuado para datos financieros complejos.

En este contexto, el presente Trabajo Fin de Máster propone la integración de estas técnicas en una arquitectura híbrida orientada al análisis de mercados financieros. En particular, se plantea el uso de *DBSCAN* como mecanismo de filtrado de anomalías, seguido de la aplicación de *K-Means* para la identificación de patrones o regímenes de mercado. Esta aproximación permite mejorar la robustez de las estrategias de *momentum*, reduciendo el impacto del ruido y de los eventos extremos en la toma de decisiones.

El objetivo principal de este trabajo es, por tanto, diseñar, implementar y evaluar un sistema híbrido que combine estrategias de compra-venta de activos (*trading*) basadas en inercia (*momentum*) con algoritmos de agrupamiento (*clustering*), con el fin de identificar patrones de comportamiento en activos financieros y mejorar la estabilidad de las estrategias de inversión en entornos de alta volatilidad. Este enfoque se sitúa en la intersección entre las finanzas cuantitativas y el aprendizaje automático, contribuyendo al desarrollo de metodologías más robustas y adaptativas en el análisis de mercados.

2. Contexto y estado del arte

El presente capítulo trata los fundamentos teóricos y matemáticos que sustentan la investigación, así como la revisión de la literatura contemporánea. En primer lugar, se analiza la naturaleza del *momentum* y su vulnerabilidad ante regímenes de alta volatilidad. Posteriormente, se muestran las herramientas de *Machine Learning* no supervisado propuestas (K-Means y DBSCAN), para finalizar con un análisis del estado del arte que justifica la arquitectura algorítmica híbrida de este trabajo.

2.1. El Momentum en los mercados financieros y el riesgo de anomalías

La persistencia de los rendimientos en los mercados de renta variable ha sido objeto de profundo debate en la literatura financiera. La Hipótesis del Mercado Eficiente (HME), o *Efficient Market Hypothesis* (EMH) establece que los precios reflejan instantáneamente toda la información disponible, imposibilitando la obtención sistemática de rendimientos anormales (Fama, 1970). Sin embargo, la evidencia empírica ha demostrado que los inversores tienden a reaccionar de forma ineficiente (por sobre-reacción o infrareacción) ante la nueva información

(Barberis et al., 1998; Hong & Stein, 1999), generando tendencias explotables matemáticamente. A la captura sistemática de estas tendencias se le conoce como inversión de *momentum*.

2.1.1. Fundamentación matemática del Momentum

El *momentum* se fundamenta en la premisa de que los activos que han obtenido un rendimiento superior en el pasado reciente continuarán haciéndolo en el futuro cercano, mientras que aquellos con un rendimiento deficiente seguirán una trayectoria bajista (Jegadeesh & Titman, 1993; Carhart, 1997). La formalización académica de esta estrategia fue establecida de forma pionera por (Jegadeesh, 1993), quienes demostraron que comprar acciones ganadoras y vender acciones perdedoras genera rendimientos anormales positivos y estadísticamente significativos.

La arquitectura matemática del modelo clásico de (Jegadeesh, 1993) se define mediante una estrategia de J meses de formación y K meses de mantenimiento (estrategia J/K). En el instante t , el universo de activos se clasifica en orden ascendente en función de sus rendimientos acumulados durante los pasados J meses. Basándose en este ránking, se forman diez carteras (deciles) equiponderadas. El decil superior se define como la cartera de "Ganadores" (*Winners*) y el decil inferior como la cartera de "Perdedores" (*Losers*).

La estrategia consiste en construir una cartera de inversión de coste cero (autofinanciada), tomando una posición larga en el decil de ganadores y una posición corta en el decil de perdedores, mantenida durante K periodos. Para maximizar el poder estadístico y evitar el sesgo de un único punto de entrada, se propone el uso de carteras superpuestas (overlapping portfolios). En cualquier mes t , la estrategia mantiene una serie de carteras seleccionadas en el mes actual y en los $K - 1$ meses anteriores, rebalanceando mensualmente una fracción $1/K$ de los pesos del hiperespacio de activos.

		Panel A				Panel B					
J		$K =$	3	6	9	12	$K =$	3	6	9	12
3	Sell		0.0108 (2.16)	0.0091 (1.87)	0.0092 (1.92)	0.0087 (1.87)		0.0083 (1.67)	0.0079 (1.64)	0.0084 (1.77)	0.0083 (1.79)
3	Buy		0.0140 (3.57)	0.0149 (3.78)	0.0152 (3.83)	0.0156 (3.89)		0.0156 (3.95)	0.0158 (3.98)	0.0158 (3.96)	0.0160 (3.98)
3	Buy-sell		0.0032 (1.10)	0.0058 (2.29)	0.0061 (2.69)	0.0069 (3.53)		0.0073 (2.61)	0.0078 (3.16)	0.0074 (3.36)	0.0077 (4.00)
6	Sell		0.0087 (1.67)	0.0079 (1.56)	0.0072 (1.48)	0.0080 (1.66)		0.0066 (1.28)	0.0068 (1.35)	0.0067 (1.38)	0.0076 (1.58)
6	Buy		0.0171 (4.28)	0.0174 (4.33)	0.0174 (4.31)	0.0166 (4.13)		0.0179 (4.47)	0.0178 (4.41)	0.0175 (4.32)	0.0166 (4.13)
6	Buy-sell		0.0084 (2.44)	0.0095 (3.07)	0.0102 (3.76)	0.0086 (3.36)		0.0114 (3.37)	0.0110 (3.61)	0.0108 (4.01)	0.0090 (3.54)
9	Sell		0.0077 (1.47)	0.0065 (1.29)	0.0071 (1.43)	0.0082 (1.66)		0.0058 (1.13)	0.0058 (1.15)	0.0066 (1.34)	0.0078 (1.59)
9	Buy		0.0186 (4.56)	0.0186 (4.53)	0.0176 (4.30)	0.0164 (4.03)		0.0193 (4.72)	0.0188 (4.56)	0.0176 (4.30)	0.0164 (4.04)
9	Buy-sell		0.0109 (3.03)	0.0121 (3.78)	0.0105 (3.47)	0.0082 (2.89)		0.0135 (3.85)	0.0130 (4.09)	0.0109 (3.67)	0.0085 (3.04)
12	Sell		0.0060 (1.17)	0.0065 (1.29)	0.0075 (1.48)	0.0087 (1.74)		0.0048 (0.93)	0.0058 (1.15)	0.0070 (1.40)	0.0085 (1.71)
12	Buy		0.0192 (4.63)	0.0179 (4.36)	0.0168 (4.10)	0.0155 (3.81)		0.0196 (4.73)	0.0179 (4.36)	0.0167 (4.09)	0.0154 (3.79)
12	Buy-sell		0.0131 (3.74)	0.0114 (3.40)	0.0093 (2.95)	0.0068 (2.25)		0.0149 (4.28)	0.0121 (3.65)	0.0096 (3.09)	0.0069 (2.31)

Cuadro 1: Rendimientos de las carteras superpuestas J/K de momentum. Fuente: Jegadeesh y Titman (1993).

Esta formulación lineal clásica ha demostrado ser rentable, pero asume implícitamente una distribución estacionaria del riesgo, una suposición que resulta matemáticamente inestable en la práctica.

2.1.2. Asimetría de riesgo y el concepto de *Momentum Crashes*

A pesar de sus altos rendimientos promedio y ratios de Sharpe atractivos, la estrategia de *momentum* presenta un riesgo de cola. La distribución de sus rendimientos está fuertemente sesgada hacia la izquierda (Barroso & Santa Clara, 2015), lo que significa que el modelo experimenta pérdidas infrecuentes pero devastadoras, conocidas en la literatura como colapsos de tendencia *Momentum Crashes* (Daniel, 2016).

Daniel y Moskowitz (Daniel & Moskowitz, 2016) demuestran que estos colapsos no son eventos aleatorios (saltos de Poisson), sino que son parcialmente predecibles al concentrarse en "estados de pánico" del mercado; es decir, tras caídas prolongadas (*bear markets*) combinadas con picos extremos de volatilidad esperada. La anatomía de una caída (*crash*) tiene una forma contraintuitiva: el colapso de la estrategia no ocurre cuando el mercado sigue cayendo, sino exactamente cuando rebota de forma abrupta.

La justificación matemática radica en la variación dinámica de la beta (β) de las carteras extremas. Tras un declive severo, las acciones del decil de "Perde-

dores"han sufrido grandes caídas, quedando a menudo en situaciones de estrés financiero. En este punto, el capital de estas empresas actúa matemáticamente como una opción de compra (*call option*) fuera del dinero sobre los activos de la empresa. Mediante la introducción de variables indicadoras de mercado bajista (I_B) y alcista (I_U), Daniel y Moskowitz (Daniel & Moskowitz, 2016) demuestran que en estados de pánico, la cartera de perdedores presenta una asimetría extrema: su beta a la baja es moderada, pero su beta al alza se dispara ante cualquier rebote positivo.

Dado que el algoritmo de *momentum* obliga a mantener una posición corta sobre estos perdedores, la estrategia se encuentra efectivamente corta en una opción de compra sobre el índice del mercado. Cuando ocurre un rebote (ej. marzo-mayo de 2009), la cartera de perdedores sube destruyendo el margen de la posición corta, mientras que la cartera de ganadores apenas sube, generando un elevado declive *drawdown* en la estrategia.




Figura 1: Evolución de las caídas catastróficas en estrategias de momentum.
Fuente: Daniel y Moskowitz (2016).

2.1.3. Ruido estructural, anomalías y la necesidad de filtrado topológico

La evidencia de los *Momentum Crashes* y la inestabilidad de los modelos lineales subraya un desafío en la econometría financiera: la baja relación señal-ruido *signal-to-noise ratio* de las series temporales. (Campbell et al., 1997) Como expone (López de Prado, 2018), los datos financieros están contaminados de forma continua por eventos de microestructura y anomalías idiosincrásicas que

no representan la dinámica real del mercado.

En este contexto, es crucial distinguir entre un cambio de régimen sistémico (donde la mayoría de los activos se desplazan conjuntamente, formando estructuras densas) y el ruido estructural o valores atípicos individuales (*outliers*). Los algoritmos de partición tradicionales, como K-Means, presentan una alta sensibilidad a estos últimos; la presencia de una sola acción con una rentabilidad extrema e injustificada puede desplazar significativamente los centroides, distorsionando la clasificación de todo el universo de activos.

Para solucionar esta limitación, la literatura técnica más reciente propone el uso de algoritmos basados en densidad. Específicamente, el algoritmo DBSCAN, Agrupamiento Espacial Basado en Densidad de Aplicaciones con Ruido (*Density-Based Spatial Clustering of Applications with Noise*), permite una aproximación topológica al filtrado de datos. A diferencia de los métodos de exclusión manuales o estáticos propuestos por autores como (Aslam, 2025), DBSCAN automatiza la identificación de anomalías basándose en la proximidad espacial de las observaciones (Shiraj, y otros, 2024). Aquellos activos que presenten movimientos de precio extremos, caídas repentinas *flash crashes* o patrones de volatilidad anómalos que no cuenten con una densidad mínima de “vecinos” con comportamiento similar, son etiquetados matemáticamente como ruido (*noise*).

Por consiguiente, se justifica la implementación de una arquitectura híbrida en este Trabajo. El uso de DBSCAN actúa como un paso de preprocesamiento para purgar las anomalías individuales y “cisnes negros” puntuales. Una vez eliminada esta contaminación estadística, el algoritmo K-Means puede clasificar los activos en regímenes de mercado robustos, garantizando que los centroides representen tendencias reales y no se vean afectados por el ruido estructural del mercado.

2.2. Fundamentos de Machine Learning no supervisado

Para abordar la naturaleza no lineal y ruidosa de los mercados financieros descrita en la sección anterior, esta investigación propone un sistema híbrido basado en dos de los algoritmos de aprendizaje no supervisado (*Unsupervised Learning*) más robustos: K-Means y DBSCAN (Bishop, 2006; Hastie et al., 2009). A diferencia del aprendizaje supervisado, estas técnicas no requieren datos etiquetados previamente, lo cual es idóneo para el descubrimiento de regímenes de mercado ocultos en series temporales multidimensionales. A continuación, se detallan sus fundamentos matemáticos.

2.2.1. Algoritmo de Agrupamiento K-Means

El algoritmo K-Means es un método iterativo que busca dividir un conjunto de n observaciones en un número predefinido de k clústeres disjuntos (MacQueen, 1967; Lloyd, 1982), de forma que cada observación pertenezca al clúster con el centroide (media) más cercano. Matemáticamente, dado un conjunto de vectores de características $X = \{x_1, x_2, \dots, x_n\}$ donde cada $x_i \in \mathbb{R}^d$ (siendo d el número de variables o indicadores financieros), el algoritmo tiene como objetivo minimizar

la varianza intra-clúster. Esto se formula como la minimización de la suma de los errores cuadráticos (*Within-Cluster Sum of Squares*, WCSS) (Jain, 2010):

$$\arg \min_C \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

Ecuación . Minimización de la suma de los errores cuadráticos

Donde $C = \{C_1, C_2, \dots, C_k\}$ representa el conjunto de clústeres y μ_i es el centroide del clúster C_i , calculado como la media aritmética de los puntos asignados a dicho clúster:

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$$

Ecuación . Media aritmética de los puntos del clúster

El proceso de optimización utiliza comúnmente la distancia euclídea como métrica de similitud en el hiperespacio d -dimensional:

$$d(x, y) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}$$

Ecuación . Distancia euclídea




Figura 2: Figura : Clasificación de activos en el espacio riesgo-rentabilidad mediante el algoritmo KMeans. Los puntos sólidos representan los centroides μ_i calculados según la Ecuación 2, mientras que las regiones sombreadas delimitan las fronteras de decisión de cada clúster. Fuente: Elaboración propia.

A pesar de su eficiencia computacional $\mathcal{O}(nki)$, el algoritmo clásico presenta dos limitaciones críticas en finanzas: asume que los clústeres tienen forma esférica (convergencia isométrica) y, al carecer de un concepto de densidad, se ve forzado a asignar todos los puntos a un clúster. Como indica la Ecuación 2, un valor atípico extremo alterará el sumatorio, desplazando el centroide μ_i y sesgando la identificación del régimen de mercado.

2.2.2. Filtro de densidad topológica DBSCAN

Para mitigar la fragilidad del K-Means ante valores extremos, se implementa el algoritmo DBSCAN, Agrupamiento Espacial Basado en Densidad de Aplicaciones con Ruido (*Density-Based Spatial Clustering of Applications with Noise*) propuesto por Ester et al. (1996). A diferencia de los métodos de partición, DBSCAN define los clústeres como regiones continuas de alta densidad de puntos separadas por regiones de baja densidad, permitiendo además la detección

automática de valores atípicos *outliers* (Schubert et al., 2017).

La topología de DBSCAN se rige fundamentalmente por dos hiperparámetros espaciales:

- ϵ (*Epsilon*): El radio máximo de vecindad alrededor de un punto.
- *MinPts*: El número mínimo de puntos requeridos dentro de la vecindad ϵ para considerar que existe una región densa.

Para cualquier punto p , su ϵ - vecindad se define matemáticamente como el subconjunto de puntos q en la base de datos D cuya distancia a p es menor o igual a ϵ :

$$N_{\epsilon}(p) = \{q \in D \mid \text{dist}(p, q) \leq \epsilon\}$$

Ecuación . Vecindad

En base a esta vecindad, el algoritmo clasifica todas las observaciones del hiperespacio en tres categorías topológicas distintas:

1. Puntos Núcleo (*Core Points*): Un punto p es un núcleo si $|N_{\epsilon}(p)| \geq \text{MinPts}$. Estos puntos conforman el interior (esqueleto) de un régimen de mercado.
2. Puntos Frontera (*Border Points*): Un punto q es frontera si $|N_{\epsilon}(q)| < \text{MinPts}$, pero pertenece a la ϵ - vecindad de un punto núcleo.
3. Ruido (*Noise / Outliers*): Cualquier punto o que no es ni núcleo ni frontera. Matemáticamente, son puntos aislados que no alcanzan la densidad crítica.




Figura 3: Figura : Clasificación topológica en DBSCAN: Identificación de puntos núcleo, frontera y ruido en función del radio ϵ y MinPts. Fuente: Elaboración propia.

En el marco de esta investigación, el objetivo primario de DBSCAN no es la clasificación final de los regímenes, sino la capacidad para detectar los puntos clasificados como Ruido". Al asignar matemáticamente la etiqueta -1 a las anomalías idiosincrásicas (como el *Flash Crash* previamente ilustrado), el algoritmo permite purgar el hiperespacio de características antes de someterlo a la minimización de la varianza del K-Means.

2.3. Estado del arte y justificación de la arquitectura propuesta

La aplicación de técnicas de *Machine Learning* no supervisado en la optimización de carteras ha experimentado un crecimiento exponencial (Gu et al., 2020; López de Prado, 2018). Sin embargo, la comunidad científica aún debate cómo gestionar la disrupción que generan las anomalías del mercado sobre los algoritmos clásicos. A continuación, se articula el estado de la cuestión siguiendo la evolución desde el problema tradicional hasta la propuesta arquitectónica de esta investigación.

2.3.1. El problema del *Momentum* tradicional en entornos volátiles

La selección de activos para conformar carteras de *momentum* ha incrementado su complejidad metodológica. Según advierte (Aslam, 2025), esta toma de decisiones representa en la actualidad un desafío mayúsculo debido a la alta volatilidad inherente a los mercados. El autor sugiere que el *momentum* transversal estándar es a menudo insuficiente en estos entornos de estrés, lo que justifica de manera imperativa la aplicación de algoritmos de Aprendizaje Automático *Machine Learning* para el desarrollo de una "estrategia de *momentum* gestionada por riesgo".

En paralelo, (Shiraj, y otros, 2024) exponen en su análisis que los mercados financieros están expuestos de forma recurrente a movimientos extremos de precios repentinos. Estos eventos anómalos o *crashes*, si no son detectados y aislados a tiempo, actúan como un factor de contaminación estadística capaz de invalidar por completo los modelos predictivos y de clasificación subyacentes.

2.3.2. El intento de solución mediante K-Means y sus limitaciones

Como respuesta a esta necesidad de adaptación dinámica, la literatura reciente ha explorado modelos de agrupamiento basados en partición. (Aslam, 2025) propone la utilización del algoritmo K-Means para clasificar el universo de activos basándose en características multidimensionales de riesgo y retorno. Su enfoque permite la identificación algorítmica de clústeres compuestos por las denominadas "acciones optimistas", superando los resultados de los deciles tradicionales.

Adicionalmente, otros trabajos contemporáneos como el de (Luan & Hamp, 2025) evidencian la necesidad de automatizar la clasificación de regímenes en series temporales multidimensionales, proponiendo variantes avanzadas del K-Means (como el *Sliced Wasserstein K-Means*) para tratar de lidiar con la complejidad de las distribuciones financieras.

No obstante, esta línea de solución presenta una limitación técnica crítica advertida por (Nyffeler, 2024): el algoritmo K-Means tradicional posee una sensibilidad matemática inherente a los valores atípicos (*outliers*). Dado que minimiza la suma de los errores cuadráticos global, la presencia de anomalías genera una severa inestabilidad en la asignación de los clústeres y una distorsión artificial en la ubicación de los centroides. Esta vulnerabilidad es ejemplificada de manera concluyente por (Bin, 2020), quien documenta cómo la caída extrema de una sola empresa (Apache Corp, -70 %) es capaz de desplazar los centroides y comprometer el rendimiento de toda una cartera K-Means.

2.3.3. Propuesta de Solución: Arquitectura Híbrida y Marco de Evaluación

La revisión del estado del arte evidencia una brecha: los algoritmos particionales (K-Means) agrupan eficientemente el riesgo, pero son incapaces de discrimi-

nar eventos irracionales, mientras que los algoritmos de densidad (DBSCAN) identifican las anomalías, pero no segmentan el mercado direccionalmente.

Para resolver esta problemática, el presente Trabajo propone una solución híbrida. Integrando las advertencias de (Shiraj, y otros, 2024) y la necesidad de gestión de riesgo de (Aslam, 2025), se establece una arquitectura secuencial: el algoritmo DBSCAN actuará como preprocesador para detectar y aislar matemáticamente las anomalías, protegiendo así al modelo. Posteriormente, K-Means clasificará el espacio de datos ya purgado, asegurando que los centroides representen los verdaderos regímenes de "acciones optimistas" sin la distorsión del ruido estructural.

Para validar de forma empírica la superioridad de esta arquitectura y mitigar el riesgo de sobreajuste (*overfitting*) advertido por (López de Prado, 2018), los hiperparámetros se optimizarán en una ventana de entrenamiento (*in-sample*) y se evaluarán en un periodo cronológico estrictamente posterior (*out-of-sample*). La investigación contrastará tres escenarios de inversión:

1. Benchmark (Referencia): Rentabilidad pasiva del índice S&P 500 (Comprar y mantener).
2. Modelo Base: Estrategia algorítmica utilizando K-Means aislado.
3. Modelo Híbrido (Propuesta): Implementación secuencial de DBSCAN seguido de K-Means.

La robustez de los modelos se medirá a través de métricas institucionales clave: el *Ratio de Sharpe* (rendimiento ajustado al riesgo) y el *Maximum Drawdown* (riesgo de caída máxima). El objetivo final de la experimentación será demostrar matemáticamente que el filtrado previo de anomalías reduce de forma efectiva las pérdidas de la cartera durante los escenarios de estrés del mercado.

3. Objetivos concretos y metodología de trabajo

En este capítulo se definen los objetivos del trabajo y la metodología seguida para su desarrollo. Este apartado actúa como nexo entre el estudio del contexto y estado del arte presentado anteriormente y la implementación práctica de la propuesta planteada.

El trabajo se enmarca en el ámbito del análisis de datos financieros mediante técnicas de *Machine Learning*, con el objetivo de desarrollar y evaluar una arquitectura algorítmica híbrida capaz de identificar patrones de comportamiento en activos financieros y reducir el impacto de anomalías en entornos de alta volatilidad.

3.1. Marco metodológico: CRISP-DM

La metodología adoptada en este trabajo se basa en el estándar *CRISP-DM* (*Cross Industry Standard Process for Data Mining*), traducido como *Proceso*

Estándar Intersectorial para Minería de Datos. Este marco fue desarrollado por un consorcio de empresas tecnológicas europeas, entre ellas *SPSS*, *Daimler-Benz* y *NCR*, como respuesta a la necesidad de estandarizar los procesos de proyectos de *minería de datos* en distintos dominios industriales (Chapman, 2000).

CRISP-DM se ha consolidado como una de las metodologías más utilizadas en proyectos de ciencia de datos debido a su carácter iterativo, flexible y centrado en el problema de negocio (Wirth & Hipp, 2000). Su estructura permite adaptar el ciclo de vida del proyecto a entornos complejos como los mercados financieros, caracterizados por ruido, no estacionariedad e incertidumbre.

El modelo CRISP-DM se compone de seis fases: (1) comprensión del negocio, (2) comprensión de los datos, (3) preparación de los datos, (4) modelado, (5) evaluación y (6) despliegue.

En este trabajo, estas fases se utilizan como marco de referencia para estructurar el desarrollo del sistema propuesto, adaptándolas al contexto del análisis de datos financieros.

En la Figura 4 se presenta una representación del ciclo CRISP-DM, el cual sirve como guía metodológica en el desarrollo del presente trabajo.




Figura 4: Diagrama del proceso CRISP-DM adaptado al español. Fuente: elaboración propia a partir de (Jensen, 2012) bajo licencia CC BY-SA 3.0.

3.2. Objetivo general

El objetivo general de este trabajo es diseñar, implementar y evaluar una arquitectura híbrida basada en técnicas de *clustering* (DBSCAN y K-Means) que permita identificar patrones de comportamiento en activos financieros y mejorar la robustez de las estrategias de *momentum* mediante el filtrado previo de anomalías.

Para ello, se desarrollará un sistema capaz de agrupar activos con dinámicas similares tras un proceso de depuración del ruido estructural, generando señales indicativas de posibles oportunidades de inversión o eventos atípicos.

El sistema propuesto será evaluado con el fin de analizar su utilidad en la interpretación del comportamiento del mercado y en la toma de decisiones basada en datos.

3.3. Objetivos específicos

Los objetivos específicos del trabajo se derivan del planteamiento general y se encuentran alineados de forma indirecta con las fases del modelo CRISP-DM, que se utiliza como marco metodológico de referencia:

1. **Recopilar** datos históricos de precios de activos financieros.
2. **Analizar** la estructura de los datos y realizar análisis exploratorio.
3. **Preprocesar y limpiar** el conjunto de datos.
4. **Transformar** series temporales en variables relevantes.
5. **Implementar** una arquitectura secuencial basada en DBSCAN y K-Means.
6. **Aplicar** DBSCAN para detección de anomalías.
7. **Aplicar** K-Means sobre datos depurados.
8. **Analizar** e interpretar los clústeres obtenidos.
9. **Integrar** una estrategia de *momentum* como marco de evaluación.
10. **Comparar** el modelo híbrido frente a un modelo base.
11. **Evaluar** el rendimiento con datos no vistos.
12. **Validar** la utilidad del modelo en entorno experimental.

3.4. Metodología del trabajo

La metodología del presente trabajo se basa en la aplicación práctica del marco CRISP-DM al desarrollo del sistema propuesto, estructurando el proceso en fases iterativas que permiten la retroalimentación continua entre obtención de datos, modelado y evaluación.

El proceso global se organiza en cuatro bloques principales: obtención y comprensión de datos, preparación de datos, modelado y evaluación.

3.4.1. Obtención y comprensión de datos

Se recopilan series temporales de activos financieros (precios de apertura, cierre, máximos, mínimos y volumen) a partir de fuentes públicas. Posteriormente, se realiza un análisis exploratorio de datos (*EDA*) para identificar patrones, distribuciones y posibles anomalías.

3.4.2. Preparación de datos

Se realiza la limpieza del conjunto de datos mediante la eliminación de valores nulos, normalización de variables y transformación de precios en retornos y medidas de volatilidad.

3.4.3. Modelado

Se implementa una arquitectura híbrida en dos etapas: DBSCAN como filtro de anomalías y K-Means como algoritmo de segmentación de regímenes de mercado.

3.4.4. Evaluación

Se evalúa el sistema mediante comparación con un modelo base y una estrategia tradicional de *momentum*, utilizando métricas financieras como rentabilidad y estabilidad.

3.5. Organización del equipo de trabajo

El desarrollo del proyecto se ha realizado de forma colaborativa entre los tres integrantes del equipo, estableciendo una distribución de responsabilidades orientada a facilitar la coordinación, aunque con participación transversal en todas las fases del proyecto.

- **Alumno 1:** diseño e implementación de la arquitectura de *machine learning*, incluyendo los algoritmos de clustering (DBSCAN y K-Means) y la construcción del sistema híbrido.
- **Alumno 2:** obtención, limpieza y transformación de los datos financieros, así como el diseño del pipeline de preprocesamiento.
- **Alumno 3:** análisis exploratorio de datos, revisión bibliográfica, apoyo en la interpretación de resultados y redacción de la memoria.

A pesar de esta distribución inicial, el trabajo ha sido completamente colaborativo, participando los tres integrantes en el diseño, validación y toma de decisiones técnicas del proyecto.

3.6. Planificación y coordinación

El equipo mantiene un sistema de reuniones periódicas:

- Reuniones semanales de seguimiento del estado del proyecto.
- Reuniones adicionales en fases críticas (preprocesamiento, modelado y evaluación).

Estas reuniones permiten revisar avances, resolver problemas técnicos y alinear decisiones metodológicas bajo el marco de CRISP-DM.

Para la coordinación del desarrollo del proyecto se ha utilizado *Git*, un sistema de control de versiones que permite registrar y gestionar los cambios realizados sobre el código a lo largo del tiempo. Como repositorio central se ha empleado *GitHub*, una plataforma en línea que facilita el trabajo colaborativo, el almacenamiento del código y la sincronización entre los distintos miembros del equipo.

Estas herramientas han permitido gestionar el desarrollo de forma estructurada, mantener un historial de cambios y facilitar la integración de las distintas partes del sistema implementado.

4. Desarrollo específico de la contribución

4.1. Selección de activos financieros y ETFs

Para el desarrollo del sistema propuesto, se ha definido un conjunto diversificado de activos financieros compuesto por acciones individuales y fondos cotizados (ETFs), con el objetivo de capturar distintos regímenes de mercado y estructuras sectoriales.

En concreto, se han seleccionado:

- Acciones del mercado español (IBEX 35), representativas de distintos sectores.
- Acciones del mercado estadounidense, caracterizadas por alta liquidez y relevancia global.
- ETFs sectoriales y de mercado, que permiten capturar dinámicas agregadas y factores sistemáticos.

La inclusión de activos de distintos mercados y sectores responde al principio de diversificación en carteras financieras, ampliamente establecido en la literatura desde la teoría moderna de carteras (Markowitz, 1952), y posteriormente desarrollado en el contexto de construcción de carteras eficientes (Elton & Gruber, 1997). Esta diversidad permite capturar comportamientos heterogéneos y reducir sesgos asociados a un único mercado.

Asimismo, la combinación de mercados internacionales se justifica por la existencia de dinámicas diferenciadas entre regiones geográficas, especialmente entre mercados desarrollados, tal y como se ha documentado en estudios sobre integración financiera internacional (Bekaert & Harvey, 1995).

Por otro lado, el uso de ETFs permite representar de forma eficiente factores de mercado y sectores económicos completos, actuando como aproximaciones agregadas del comportamiento del mercado y reduciendo el impacto del ruido idiosincrático de activos individuales (Madhavan, 2012).

Además, la inclusión de activos pertenecientes a distintos sectores económicos se fundamenta en la evidencia de que los retornos presentan estructuras diferenciadas en función del sector, lo que resulta relevante en tareas de segmentación y clustering financiero (Fama & French, 1997).

Finalmente, la selección de activos líquidos y ampliamente negociados responde a la necesidad de garantizar la calidad de los datos y evitar distorsiones asociadas a problemas de iliquidez, tal y como se ha señalado en la literatura sobre microestructura de mercados (Amihud, 2002).

En la Tabla 2 se presenta el universo de activos financieros utilizado en el desarrollo del sistema propuesto, incluyendo acciones de los mercados español y estadounidense, así como distintos fondos cotizados (ETFs) representativos de sectores, índices y factores de riesgo.

Ticker	Activo	Categoría
Mercado España (IBEX 35)		
SAN.MC	Banco Santander	Acción
FER.MC	Ferrovial	Acción
ACS.MC	ACS	Acción
ITX.MC	Inditex	Acción
REP.MC	Repsol	Acción
AMS.MC	Amadeus IT Group	Acción
Mercado Estados Unidos		
AAPL	Apple Inc.	Acción
MSFT	Microsoft	Acción
NVDA	NVIDIA	Acción
JPM	JPMorgan Chase	Acción
BLK	BlackRock	Acción
TSLA	Tesla	Acción
DPZ	Domino's Pizza	Acción
CAT	Caterpillar	Acción
XOM	Exxon Mobil	Acción
ETFs		
XLK	Technology Select Sector ETF	ETF Sectorial
SMH	Semiconductor ETF	ETF Sectorial
XLV	Health Care ETF	ETF Sectorial
XLI	Industrial ETF	ETF Sectorial
XLY	Consumer Discretionary ETF	ETF Sectorial
XLP	Consumer Staples ETF	ETF Sectorial
GLD	SPDR Gold Trust	ETF Materias Primas
SPY	S&P 500 ETF	ETF Índice
QQQ	Nasdaq-100 ETF	ETF Índice
EWP	Spain ETF	ETF País
MTUM	Momentum Factor ETF	ETF Factorial
XLE	Energy ETF	ETF Sectorial
XLF	Financials ETF	ETF Sectorial
TLT	Treasury Bonds ETF	ETF Renta Fija
XLU	Utilities ETF	ETF Sectorial

Cuadro 2: Universo de activos financieros utilizados en el sistema propuesto.

5. Referencias bibliográficas

- Aslam, B. (2025). Identifying optimistic stocks with K-means clustering algorithm. *International Review of Economics & Finance*, 104579.
- Bin, S. (2020). K-means stock clustering analysis based on historical price movements and financial ratios (Senior thesis). *Claremont McKenna College*.
- Daniel, K. M. (2016). Momentum crashes. *Journal of Financial Economics*, 221-247.
- Jegadeesh, N. T. (1993). Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. *The Journal of Finance*, 65-91.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- Luan, Q., & Hamp, J. (2025). Automated regime classification in multidimensional time series data using sliced Wasserstein k-means clustering. *Data Science in Finance and Economics*, 387-418.
- Nyffeler, L. (2024). K-means clustering with Mahalanobis distance for stock classification into value and growth portfolios (Bachelor's thesis). *Zurich University of Applied Sciences (ZHAW)*.
- Shiraj, M., Rahman, M., Al-Imran, M., Liza, M., Murshed, M., & Akhter, N. (2024). Anomaly detection in financial time series data via mapper algorithm and DBSCAN clustering. *World Journal of Advanced Engineering Technology and Sciences*, 70-84.

Referencias

- Amihud, Y. (2002). Illiquidity and stock returns: cross-section and time-series effects. *Journal of financial markets*, 5(1), 31-56.
- Bekaert, G., & Harvey, C. R. (1995). Time-Varying World Market Integration. *The Journal of Finance*, 50(2), 403-444. <https://doi.org/https://doi.org/10.1111/j.1540-6261.1995.tb04790.x>
- Chapman, P. (2000). CRISP-DM 1.0: Step-by-step data mining guide. <https://api.semanticscholar.org/CorpusID:59777418>
- Elton, E. J., & Gruber, M. J. (1997). Modern portfolio theory, 1950 to date. *Journal of Banking & Finance*, 21(11), 1743-1759. [https://doi.org/http://doi.org/10.1016/S0378-4266\(97\)00048-4](https://doi.org/http://doi.org/10.1016/S0378-4266(97)00048-4)
- Fama, E. F., & French, K. R. (1997). Industry costs of equity. *Journal of financial economics*, 43(2), 153-193.
- Jensen, K. (2012). CRISP-DM Process Diagram [Licencia CC BY-SA 3.0, consultado el 2026-05-01]. https://commons.wikimedia.org/wiki/File:CRISP-DM_Process_Diagram.png
- Madhavan, A. (2012). Exchange-traded funds, market structure, and the flash crash. *Financial Analysts Journal*, 68(4), 20-35.
- Markowitz, H. (1952). Modern portfolio theory. *Journal of Finance*, 7(11), 77-91.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining*, 1, 29-39.